



UNIVERSIDADE FEDERAL DO AMAPÁ
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO
DEPARTAMENTO DE CIÊNCIAS EXATAS E TECNOLÓGICAS

DETECTA POTOCA: UMA ABORDAGEM DE APRENDIZADO DE MÁQUINA PARA A DETECÇÃO DE "FAKE NEWS" SOBRE COVID-19 NO AMAPÁ

RODRIGO SANTOS BALIEIRO

Orientador: Prof. Dr. José Walter Cárdenas Sotil

MACAPÁ
MARÇO DE 2020

RODRIGO SANTOS BALIEIRO

**DETECTA POTOCA: UMA ABORDAGEM DE APRENDIZADO
DE MÁQUINA PARA A DETECÇÃO DE "FAKE NEWS" SOBRE
COVID-19 NO AMAPÁ**

Trabalho de Conclusão de Curso apresentado à Universidade Federal do Amapá como requisito parcial para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. José Walter Cárdenas Sotil

MACAPÁ
MARÇO DE 2020

Primeiramente a Deus, pela oportunidade de chegar até aqui. Aos meus pais, minha esposa Aline e ao meu filho Paulo Henrique e a toda comunidade acadêmica que de forma direta e indireta contribuiu para a realização deste trabalho.

Agradecimentos

Inicialmente, agradeço à Deus, pela vida e saúde e pela força para poder seguir em frente até o final deste trabalho embora tenham havido muitos problemas. Posteriormente agradecer à minha família pelo apoio e força moral, aos meus professores que dedicaram seu tempo para ajudar a coletar informações para que eu conseguisse pesquisar e concluir o presente trabalho e, em especial, meu orientador José Walter Cárdenas Sotil pela paciência e dedicação ao conduzir este trabalho até o fim.

"Fake News mata, e mata mais que vírus e bactérias. Se uma pessoa começa a divulgar que a vacina tem substâncias tóxicas, que tem um microchip que vai copiar ou rastrear você, uma pessoa que minimamente não consegue se informar vai deixar de se imunizar e se expor a um risco que pode levá-la à morte", dissertou a Diretora da Sociedade Brasileira de Imunizações (SBIIm) – Mônica Levi.

Resumo

Com o uso mais frequente das redes sociais, a opinião pública cada vez mais está associada às informações postadas nos grupos desses ambientes virtuais. Existem pessoas usando esse cenário para divulgar *Fake News* para manipular as decisões, discussões e a realidade popular, sendo necessário um contra-ponto acadêmico, científico e jornalístico àquelas ações: a detecção de notícias falsas, do que trata este trabalho.

Palavras-chave: Fake News. Checagem. Classificação de palavras.

Abstract

With the more frequent use of social networks, public opinion is increasingly associated with information posted in groups in these virtual environments. There are people using this scenario to spread Fake News to manipulate decisions, discussions and popular reality, requiring an academic, scientific and journalistic counterpoint to those actions: the detection of false news, which this work is about.

Keywords: Fake News. Check. Word classification.

Lista de Figuras

Figura 1 – Estatística Covid-19. Jan/2020-Fev/2021. Fonte Min. Saúde[1]	10
Figura 2 – Gráficos de mineração de dados - Crédito QA Stack[2]	19
Figura 3 – Representação da Fórmula de Classificação/Regressão[3]	20
Figura 4 – Gráfico da Regressão Logística	25
Figura 5 – Exemplo de uma tabela do banco de dados do Fakecheck	35
Figura 6 – Base de Dados com o Dataframe embaralhado	35
Figura 7 – Frequências e Probabilidades das palavras do Dicionário	39
Figura 8 – Array do Eixo Y	40
Figura 9 – Dados de treinamento e dados de teste 1	41
Figura 10 – Dados de treinamento e dados de teste 2	42
Figura 11 – Dados de treinamento e dados de teste 3	42
Figura 12 – Regressão Logística 1	43
Figura 13 – Regressão Logística 2	44
Figura 14 – Regressão Logística	44
Figura 15 – Matriz de Confusão	46
Figura 16 – Cálculo da Acurácia	47
Figura 17 – Resultados da Acurácia	47
Figura 18 – Curva ROC	48

Lista de Algoritmos

Algoritmo 1 – Instalação das Bibliotecas Python	30
Algoritmo 2 – Criar arquivo do tipo Dataframe	34
Algoritmo 3 – Exibir as 5 primeiras linhas do Dataframe	34
Algoritmo 4 – Número de Notícias Falsas e Verdadeiras	34
Algoritmo 5 – Dataframe embaralhado	35

Lista de Abreviaturas e Siglas

AUC	Area Under the Curve
ROC	Receiver Operating Characteristic
PF	Polícia Federal
NLTK	Natural Language Tool Kit
OMS	Organização Mundial da Saúde
OPAS	Organização Pan-Americana de Saúde
RL	Regressão Logística
GB / gb	Gigabytes
TB / tb	Terabytes
SSD	Solid State Drive
AM	Aprendizado de Máquina
PCA	Principal Component Analysis
SVD	Singular Value Decomposition
LDA	Latent Dirichlet Allocation
LSA	Latent Semantic Analysis
SARSA	Estado-Ação-Recompensa-Estado-Ação

Sumário

1 – Introdução	1
1.1 Organização do Trabalho	3
1.2 Fake News	3
1.3 Potencial Negativo das Fake News	3
1.4 Propagação das Fake News	4
1.5 Motivação	4
1.6 Perfil do Usuário de redes sociais	5
1.7 O COVID-19	6
1.8 Notícias falsas e suas principais consequências	11
1.9 Tipos de Notícias Falsas a Serem Detectadas	13
2 – Técnicas Computacionais para Detectar Notícias Falsas	16
2.1 Processamento de Linguagem Natural(PLN)	16
2.2 NLTK	16
2.3 Ciência de Dados	17
2.4 Aprendizado de Máquina(AM)	17
2.4.1 O Processo de Aprendizagem	21
2.4.2 Aprendizado Supervisionado	21
2.4.3 Aprendizado Não-supervisionado	22
2.4.4 Aprendizado por Reforço	23
2.5 Regressão Logística(RL)	23
2.6 Exemplos de Detectores de Fake News	26
3 – FakeCheck para Detectar Fake News regionais do Amapá	27
3.1 Justificativa	27
3.2 Objetivos	28
3.2.1 Geral	28
3.2.2 Específicos	28
3.3 Metodologia	28
3.4 Recursos Utilizados	28
3.4.1 Métricas de Avaliação	29
3.5 Relatório do Software	29
4 – Resultado e Discussão	34
4.1 Banco de Dados	34
4.2 Pré-Processamento	36

4.3	Dados de Treinamento e Dados de Teste	41
4.4	Regressão Logística	43
4.5	Avaliação do Modelo: Métricas	45
5	Conclusão e Contribuições para Trabalhos Futuros	49
	Referências	50

1 Introdução

As informações acompanham a história da humanidade desde que nos entendemos enquanto sociedade. Para Nelson Traquina, as notícias podem ser definidas [4] como a narrativa de um fato com relevância social. Para Felipe Pena[5], as notícias fazem parte de um dos principais fatores que permitem as pessoas se comunicarem. Já os cientistas sociais Miriam Grossi e Rodrigo Toniol acreditam que as notícias e suas editoriais permitem que as pessoas tomem decisões importantes para suas vidas a partir do entendimento do conteúdo que leem[6].

O que pode-se observar é que a notícia tem notável importância na sociedade, mas os meios que a tornam acessíveis têm variado de acordo com a popularização de tecnologias, principalmente das que apresentam conexão com a internet.

Os meios de comunicação jornalísticos evoluíram e mudaram suas abordagens de acordo com a evolução tecnológica social, como explicado por Traquina[4]: Passou-se da escrita à mão para a prensa – tínhamos aí o jornal impresso. Depois veio o rádio com as vozes e os efeitos. Aí surgem os telejornais com as imagens da televisão. Quando tudo parecia já resolvido, a internet abriu um leque de opções de informações que permitiu ter todos eles em um universo no qual cada um escolhe que conteúdo quer consumir e produzir.

Pena[5] afirma que ao contrário do que se imaginava, um canal de comunicação não extinguiu o outro, apenas abriu mais possibilidades de acesso à informação – o que permite às pessoas um maior entendimento sobre determinado assunto ou fato ocorrido.

Entretanto, com o surgimento de diversos dispositivos móveis, capazes de se conectar a internet, as informações passaram a ter uma característica, como afirmam as pesquisadoras Fabiana Monteiro e Patrícia Siqueira, muito volátil. Isto quer dizer que muitas informações são produzidas em um curto espaço de tempo e, algumas delas ganham o adjetivo "viral", por serem muito acessadas e compartilhadas entre as pessoas[7].

Pela peculiaridade das notícias de grande abrangência assemelham-se com vírus, cientistas como Shu e Liu[11], comparam os malefícios sociais das notícias falsas aos que os vírus biológicos e de computador podem provocar, pois podem se propagar com alta velocidade influenciando tanto debates familiares quanto grandes decisões políticas, marcando, assim, a vida das pessoas.

No final do ano de 2019, um vírus foi descoberto da cidade de Wuhan, na China, o novo Coronavírus. O mesmo rapidamente se espalhou pela Ásia e Europa, fazendo

com que a Organização Mundial da Saúde alertasse os países do mundo todo sobre a gravidade do mesmo e sobre as formas de evitar muitos óbitos. Entretanto, no início de 2020, a organização classificou a contaminação pelo novo vírus como pandemia, impactando toda vida social das pessoas no planeta, influenciando no hábito cotidiano e na economia das nações.

Mesmo esse fato sendo amplamente difundido pelos meios de comunicação de massa, muitos discursos foram criados, negando a existência da doença e das mortes, com formas de tratamento sem base científica, minimização da gravidade da doença, manipulação do fato para fins políticos, ideológicos, religiosos, financeiros e comerciais. Foram tantas informações inverídicas ao longo dos anos de 2020 e 2021 que vários órgãos criaram formas de checar se as informações publicadas sobre o Coronavírus nas redes sociais eram verdadeiras ou falsas.

Um termo muito comum usado nas redes sociais sobre conteúdo falso nesse período foi *Fake News*, que ganhou popularidade na época da eleição norte-americana de 2016 quando se propagaram diversas informações falsas sobre os candidatos a presidência a fim de denegrir a imagem do outro, mas que tiveram consequências sociais além das eleições e da própria política.

Isto posto, o surgimento do presente trabalho parte da problemática cada vez mais comum do aumento no acesso à conteúdo publicado na internet, principalmente redes sociais e o potencial negativo que essas informações podem causar, particularmente no que se refere a Covid-19, doença provocada pelo novo Coronavírus, no cenário brasileiro e no estado do Amapá.

Em termos de regionalização das *Fake News*, vale destacar que o governo do estado do Amapá aprovou uma lei para multar as pessoas que divulgarem notícias falsas sobre qualquer assunto relacionado a epidemias ou doenças como o coronavírus[8].

Existem várias agências de checagem das informações e, mesmo as redes sociais a cada dia aprimoram seus algoritmos e termos de uso para evitar que conteúdos falsos e cibercrimes sejam difundidos, entretanto, para muitos usuários daquelas redes sociais não têm conhecimento dos recursos que atestam a veracidade das informações que são publicadas e outras, nem mesmo permitem que conteúdos sejam acessados de forma pública, tendo suas informações restritas às pessoas do grupo as quais pertencem. Por este motivo, a rede social mais fácil de ser analisada até a presente data foi o aplicativo de mensagens *Twitter* que, embora não seja o mais acessado, de acordo com a pesquisa do DataSenado [9], por ter um conteúdo largamente difundido a público aberto, exerce uma grande influência nas decisões e na formação de opinião pública dos brasileiros, sendo uma fonte para novas publicações em outros aplicativos com grande acesso popular no Brasil, como Instagram, Facebook e Whatsapp.

Dessa forma, este trabalho pretere um estudo acerca de um detector de *Fake News*, partindo do aplicativo de código aberto "FakeCheck" para manter uma acurácia satisfatória e capaz de propor, através da aprendizagem de máquina, uma sugestão ao usuário se o conteúdo acessado é verdadeiro ou falso.

1.1 Organização do Trabalho

No capítulo introdutório é apresentado o termo *Fake News*, sua definição, seu potencial negativo, as formas de propagação, o perfil de quem cria e compartilha e, de que forma podem ser detectados.

No capítulo seguinte, são apresentadas as técnicas computacionais para detectar notícias falsas, compreendendo diversas áreas da computação como Ciência de Dados, Aprendizagem de Máquina, Inteligência Artificial, bem como a linguagem de programação utilizada que foi Python e seu conjunto de bibliotecas para facilitar o processamento e classificação de informações coletadas no bando de dados.

O terceiro capítulo discorre a respeito do Objeto de estudo, a justificativa para sua utilização, os objetivos, a metodologia utilizada, os recursos e o relatório elaborado com base na execução do software em questão.

O quarto capítulo relata os resultados obtidos a partir do modelo treinado do software apresentado, apresentando números e gráficos obtidos na execução do algoritmo.

O quinto e último capítulo do presente trabalho apresenta a conclusão e de que forma o aprendizado de máquina pode ser importante para a detecção de notícias falsas a respeito do Coronavírus e de que maneira ele pode auxiliar na tomada de decisões do público que acessa as redes sociais.

1.2 Fake News

Um breve apanhado histórico, tanto das notícias falsas e suas consequências quanto das formas de aprendizado de máquina para detectá-las.

1.3 Potencial Negativo das Fake News

Em uma tradução livre o termo *Fake News*, que vem da língua inglesa, pode ser expresso como *notícias falsas*. Entretanto existem algumas definições a mais para esse termo, principalmente depois da popularidade que ele recebeu durante as eleições presidenciais norte-americanas de 2016.

Claire Wardle, na obra conjunta de Julie Posetti[10], define *Fake News* como desinformação, pois ela cogita a ideia de que o(s) autor(es) deste tipo de conteúdo o fazem com vários objetivos que não o de informar.

Existe uma definição acerca do termo aqui tratado como sendo uma notícia comprovada e intencionalmente falsa. Isto quer dizer que, neste caso, as *Fake News* são bem produzidas, não sendo apenas uma falha de interpretação ou mero erro publicado, mas algo premeditado e estruturado com uma finalidade específica[11, 12].

Na visão do pesquisador indiano Mohammed Alkawaz[12], não somente o texto original que publica a *Fake News* como seu compartilhamento e comentários a respeito dele também são considerados como notícias falsas porque propagam o objetivo delas que é desinformar, distrair atenções de um problema existente ou popularizar uma ideologia.

No Brasil, o termo *Fake News* foi associado como crime cibernético, embora não haja lei específica sobre esta terminologia, mas juristas têm feito a analogia das consequências dos conteúdos publicados com crimes previstos no código penal[13], como difamação(art. 139), injúria(art. 140), calúnia(art. 138), principalmente se publicadas próximo às eleições e, no presente contexto deste trabalho, durante a pandemia do Coronavírus.

É importante essa definição do termo porque existem outros tipos de publicações na internet similares as que estarão sendo analisadas aqui neste trabalho, entretanto, não comporão o banco de dados do protótipo. Uma delas é a sátira[14], em que existe a intenção de expor uma informação falsa, mas no formato de peça teatral com intuito de diversão; outro exemplo são falhas de interpretação, que são comuns em leitores jovens, cuja intenção não fosse obter grande notoriedade pública ou causar tendências comportamentais[11].

1.4 Propagação das Fake News

As notícias falsas geralmente se caracterizam pela propagação em massa, isso se dá pelo compartilhamento de informações via internet, geralmente em redes sociais ou mídias digitais[10, 15].

1.5 Motivação

Pelo contexto em que se passa o presente trabalho, onde vários problemas sociais se agravam associados ao vírus Sars-cov-2, em que diversas áreas do conhecimento buscam formas de amenizar tais problemas e solucionar as diversas sequelas deixadas pela doença, a utilização de um detector de notícias falsas é uma forma de contribuir

diretamente com todos esses esforços, aliando o conhecimento acadêmico e científico a fim de combater a desinformação e a má formação de opinião.

1.6 Perfil do Usuário de redes sociais

Antes de pretender detectar notícias falsas é importante traçar o perfil da fonte, ou seja, de quem produz quanto de quem as consome e compartilha-as. Como observado por Kai Shu e Huan Liu[11], os usuários procuram informação por diversas áreas do conhecimento, mas o foco observado por disseminadores de notícias falsas são áreas como política e entretenimento, nos quais se observam comportamentos padrões no acesso.

Levando em consideração a pesquisa do "DataSenado" de 2019[9], 79% dos brasileiros entrevistados afirmaram que tinham como principal fonte de informação o conteúdo de suas redes sociais. A mesma conclusão pode-se inferir a respeito da pesquisa do Instituto Brasileiro de Geografia e Estatística (IBGE) de 2019[16], em que avaliou o uso de internet, tv e celular no Brasil, apontando o uso majoritário de internet e celular com consumo de informação proveniente das redes sociais.

É importante destacar que os consumidores das informações divulgadas na internet procuram cada vez mais conteúdos específicos de interesse próprio, ressaltando a importância das redes sociais na geração e consumo de dados a todo momento, em muitos casos, tendo este meio de comunicação como única fonte de pesquisa e informação, desprezando meios tradicionais de comunicação como rádio, tv, jornais impressos e revistas[17].

De acordo com o estudo de Shu e Liu[11], embora muitos usuários nas redes sociais sejam legítimos, alguns podem ter más intenções e, em alguns casos, nem mesmo são pessoas reais. O baixo custo e a facilidade de criação de contas em uma rede social são um incentivo para o surgimento de usuários mal-intencionados, como *Bots Sociais* e *Trolls*. Um **Bot** refere-se a uma conta de mídia social controlada por um algoritmo de computador para produzir conteúdo automaticamente e interagir com as pessoas (ou outro *bot*) nas redes sociais. Os *bots* podem se tornar entidades maliciosas projetadas especificamente com o propósito de causar danos, como manipular e divulgar notícias falsas nas redes sociais[17].

Estudos mostram que os *bots* sociais distorceram as discussões online da eleição presidencial dos EUA de 2016 em grande escala[18], e que cerca de 19 milhões de contas de *bots* "tweetaram" em apoio ao candidato a presidente da república na época Donald Trump na semana anterior ao dia da eleição[10].

Já os **Trolls**, diferente dos *bots*, são usuários humanos reais que visam perturbar

comunidades online e provocam uma resposta emocional dos consumidores. Eles também estão fazendo um papel importante na divulgação de notícias falsas nas redes sociais. Por exemplo, ainda sobre as eleições presidenciais norte-americanas de 2016, as evidências sugerem que haviam 1.000 *trolls* russos pagos espalhando notícias falsas sobre Hillary Clinton[19].

Os comportamentos de "trolagem" são altamente afetados pelas emoções das pessoas e pelo contexto das discussões online, o que permite a fácil disseminação de notícias falsas entre comunidades online "normais". O efeito da "trollagem" é desencadear as emoções negativas internas das pessoas, como raiva e medo, resultando em dúvida, desconfiança e comportamento irracional[11]. Em suma, essas contas maliciosas altamente ativas e partidárias nas redes sociais tornam-se fontes poderosas de proliferação de notícias falsas[17, 11, 19].

1.7 O COVID-19

De acordo com a Organização Pan-Americana de Saúde (OPAS)[20], no dia 31 de dezembro de 2019, foram registrados, pela Organização Mundial da Saúde (OMS) vários casos de pneumonia, na cidade chinesa de Wuhan, província de Hubei, o que se tratava de um novo tipo de coronavírus, que ainda não havia sido identificada em seres humanos.

Posteriormente, em 7 de janeiro de 2020, as autoridades da China confirmaram a existência de um novo tipo de coronavírus, com um nível de contágio bem alto.

A OPAS[20] divulga que existem sete tipos de coronavírus HCoV-229E, HCoV-OC43, HCoV-NL63, HCoV-HKU1, SARS-COV, MERS-COV e, o mais recente, SARS-CoV-2, responsável por causar a doença da COVID-19, que ganha esta nomenclatura por ser um coronavírus descoberto em 2019.

Depois de um ano de convivência mundial com o novo coronavírus, pode-se destacar uma cronologia[21, 22] da COVID-19:

- **31 de dezembro de 2019:** O escritório da OMS na China é informado de casos de uma pneumonia em Wuhan.
- **10 de janeiro de 2020:** A primeira morte pela nova doença é informada na China, mas ainda em investigação.
- **21 de janeiro de 2020:** A morte de um homem norte-americano, que havia viajado para Wuhan, é confirmado como de síndrome respiratória, associada à nova doença.

- **24 de janeiro de 2020:** Duas pessoas na França foram detectadas com o coronavírus, que fizeram viagem para a China, onde já havia cerca de 800 infecções e 26 mortes.
- **06 de fevereiro de 2020:** Governo Federal sanciona lei da quarentena, em que visava por em observação os brasileiros que chegassem ao Brasil tendo viajado pela China. No dia 09 do mesmo mês, um avião, contendo 34 passageiros, provenientes de Wuhan, na China, permaneceram em quarentena na cidade de Anápolis-GO por 18 dias.
- **26 de fevereiro de 2020:** O Ministério da Saúde confirma o primeiro caso de Coronavírus no Brasil, sendo um homem de 61 anos de idade, de São Paulo, que teria viajado para a Itália, que na época foi considerado o epicentro da doença, tendo registrado 15,8 mil mortes. Já o primeiro óbito no Brasil ocorreria em 12 de março.
- **11 de março de 2020:** A Organização Mundial da Saúde declara oficialmente a Covid-19 como uma pandemia em função dos "níveis alarmantes" de propagação em diferentes países. A Europa começa a falar no termo "lockdown" para conter o avanço da transmissão. No mesmo dia, o Governo do Distrito Federal foi a primeira unidade da federação a suspender as aulas nas redes pública e privada por cinco dias.
- **12 de março de 2020:** Integrantes do Governo Federal contraem a doença, com uma comitiva de mais de 20 pessoas, incluindo o general Augusto Heleno e o secretário de comunicação Fábio Wanjgarten testaram positivo para Covid-19.
- **16 de março de 2020:** Aulas são suspensas, na tentativa de conter a pandemia de Covid-19, o que leva a uma paralisação do sistema de ensino no estado do Rio Grande do Sul.
- **17 de março de 2020:** O Brasil teve a primeira morte por coronavírus confirmada em São Paulo, sendo um homem de 62 anos.
- **22 de março de 2020:** Medida Provisória presidencial flexibilizou regras trabalhistas estabelecendo regras para o teletrabalho, férias individuais, coletivas e banco de horas.
- **24 de março de 2020:** Presidente da República pede volta à normalidade e fim do confinamento em massa.
- **24 de março de 2020:** Japão anuncia cancelamento das olimpíadas para o ano de 2021 por causa do perigo de contágio da Covid-19.
- **25 de março de 2020:** Governadores criticam pronunciamento do presidente e mantêm iniciativas de quarentena.

- **26 de março de 2020:** Cidades sem movimento nas ruas após um mês da doença, atendendo às novas regras de quarentena regidas pelos governos estaduais.
- **28 de março de 2020:** Mais de 100 mortes por Covid-19 são registradas no Brasil, após 11 dias da confirmação do primeiro óbito.
31 de março de 2020: Morre homem de 23 anos de idade. O gastrólogo Matheus Aciole teve a morte confirmada por Covid-19, sendo o brasileiro mais jovem a perder a vida na ocasião e, indo de encontro a informação de que a doença vitimava apenas pessoas idosas ou com comorbidades.
- **01 de abril de 2020:** Medida Provisória presidencial da Redução Salarial. Esta medida permitiu a suspensão de contratos de trabalho e a redução da jornada de trabalho, juntamente com os salários para evitar demissões em massa.
- **02 de abril de 2020:** Auxílio de R\$ 600,00. Ficou conhecido como auxílio emergencial. Foi publicado no Diário Oficial da União e foi destinado a trabalhadores informais e pessoas de baixa renda para conter os impactos financeiros deixados pela pandemia.
- **2 de abril de 2020:** A pandemia chega a marca de 1 milhão de infectados em 171 países de todos os continentes, somando cerca de 51 mil mortes.
- **06 de abril de 2020:** Morrem adolescente e bebê. Em Recife, um jovem de 15 anos teve a morte confirmada pelo coronavírus e, no mesmo dia, um bebê, no Ceará, também teve um óbito confirmado pela doença.
- **8 de abril de 2020:** Brasil supera a marca de 2000 casos por dia de coronavírus e Europa tem declínio nos casos devido às restrições impostas pelas autoridades.
- **03 de maio de 2020:** Brasil registra mais de 100 mil casos de coronavírus. O número de casos dobrou em menos de 10 dias.
- **05 de maio de 2020:** O Brasil contabilizou 600 mortes por Covid-19 em 24 horas. O número fez com que os governos estaduais intensificassem as medidas de contenção do contágio do vírus.
- **11 de maio de 2020:** Entra em vigor o sistema de distanciamento controlado, que classifica a região por cores conforme o grau de risco, sistema adotado por estados como Rio Grande do Sul, São Paulo e Rio de Janeiro.
- **18 de maio de 2020:** Amapá é o primeiro estado brasileiro a decretar "Lock-down" em todos os municípios. Medida imposta pelo governador inclui medidas rígidas de distanciamento, restrição de circulação, comércio, serviços e rodízio de veículos.

- **28 de maio de 2020:** Nos Estados Unidos são registrados mais de 100 mil óbitos por Covid-19, por isso, os governos estaduais daquele país intensificaram as medidas de distanciamento social, higiene das mãos e uso de máscaras.
- **17 de junho de 2020:** A OMS anuncia a interrupção definitiva de testes com hidroxiclороquina após avaliar que não reduzia a mortalidade da doença Covid-19. Ainda assim, o medicamento seguiu como principal estratégia do governo do Brasil contra o vírus Sars-Cov-2.
- **31 de julho de 2020:** A Fundação Oswaldo Cruz (FIOCRUZ) e o laboratório AstraZeneca assinaram acordo para transferência de tecnologia e produção da vacina de Oxford para prevenção da Covid-19.
- **11 de agosto de 2020:** A Rússia anuncia a primeira vacina pronta contra o Coronavírus, chamada de SPUTNIK-V, mas teve desconfiança da comunidade científica mundial pela forma como foi produzida.
- **28 de setembro de 2020:** O mundo registra mais de 1 milhão de mortos por coronavírus desde o início da pandemia. No mesmo período, 22,7 milhões de infectados conseguiram se recuperar da doença.
- **07 de outubro de 2020:** O Estado do Rio Grande do Sul notifica mais de 5 mil mortos por Covid-19, em uma média diária de 25 vidas perdidas.
- **17 de outubro de 2020:** Países como Itália e Espanha retomam medidas de restrições e quarentenas, após um aumento no registro de mortes por coronavírus em uma possível "segunda onda".
- **24 de novembro de 2020:** Brasil supera a marca de 170 mil óbitos por Covid-19, enquanto a taxa de transmissão do vírus é a maior desde maio do mesmo ano, conforme estudos do Imperial College de Londres.
- **08 de dezembro de 2020:** O Reino Unido é o primeiro país a iniciar uma campanha de vacinação em massa com um imunizante aprovado clinicamente, com doses do laboratório estadunidense BionTech/Pfizer. Semanas depois, aprovaria o uso da vacina da Universidade de Oxford, na Inglaterra para iniciação em massa para janeiro de 2021.
- **14 de janeiro de 2021:** Crise da falta de oxigênio no estado do Amazonas. Nos dias 14 e 15 a capital Manaus teve um colapso no sistema de saúde em decorrência da falta de insumo, essencial para tratar casos graves de Covid-19.
- **17 de janeiro de 2021:** O Estado de São Paulo é o primeiro a iniciar a vacinação contra a Covid-19.

- **12 de março de 2021:** Brasil se torna o epicentro de Covid-19 no mundo e países evitam chegada de brasileiros em seus aeroportos.
- **31 de março de 2021:** Brasil supera marca de mais de 4000 mortes diárias por coronavírus.
- **22 de julho de 2021:** Anunciada descoberta da variante Delta da Covid-19 no Brasil, proveniente da cepa indiana, com uma mortalidade maior em relação ao vírus que já circulava no país.

Abaixo está um gráfico divulgado pelo Ministério da Saúde do Brasil que mostra números de casos e óbitos do início da pandemia até novembro de 2021, quando foi pesquisado no presente trabalho.

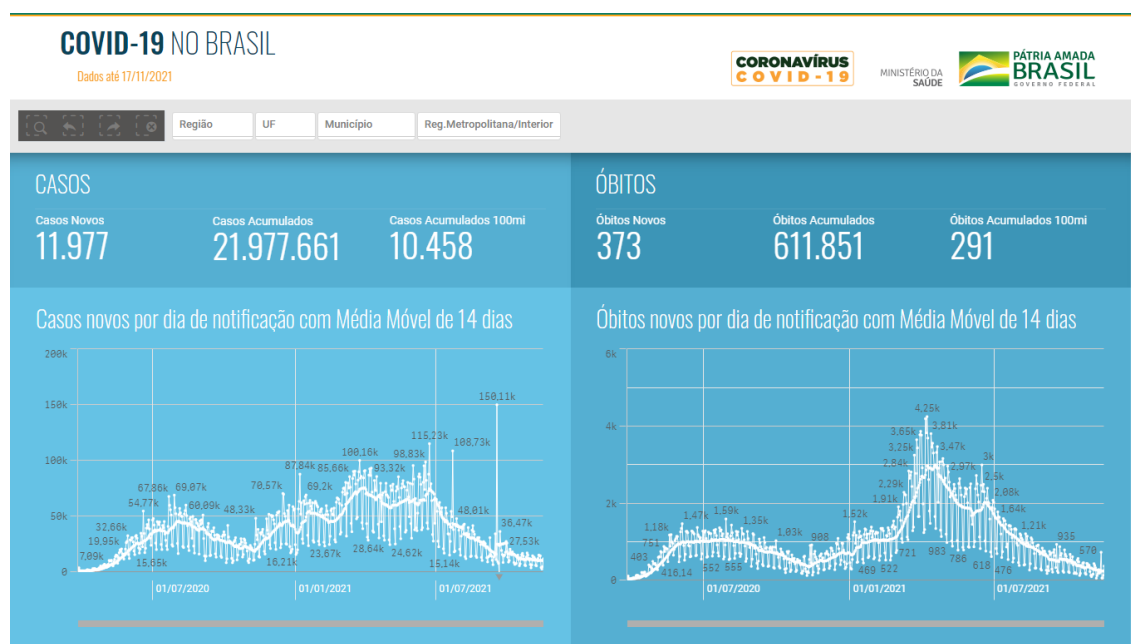


Figura 1 – Estatística Covid-19. Jan/2020-Fev/2021. Fonte Min. Saúde[1]

1.8 Notícias falsas e suas principais consequências

Para Shu e Liu[11], três fatores foram muito importantes, nos últimos anos, para que as pessoas passassem a procurar mais a informação de fontes da internet, incluindo as redes sociais: o fácil acesso, rápida disseminação e baixo custo. Entretanto, as redes sociais[15] também são usadas como disseminadoras de informações falsas, que são manipuladas com objetivos específicos[23].

Em um artigo publicado no jornal inglês *The Guardian*, o autor John Naughton evidenciou uma fala do diretor da Organização Mundial da Saúde, que discursava sobre os perigos do vírus COVID-19: "Não estamos apenas lutando contra uma epidemia; estamos lutando contra um *infodêmico*. Notícias falsas se espalham com mais rapidez e facilidade do que esse vírus e são igualmente perigosas"[24]. Sobre essa fala é possível notar que as principais autoridades de saúde e até mesmo formadores de opinião em vários países no mundo se preocupam com a disseminação de notícias falsas e suas consequências, sendo um grande fator na contenção do coronavírus.

Para um grupo de pesquisadores[25], os agentes responsáveis pela divulgação de notícias falsas podem ser identificados como profissionais ou amadores. Este último é associado a pessoas que levantam boatos para se manter populares, comunicativas e, que geralmente, o fazem sem conceber a repercussão de seu ato. Julie Posetti[10] lembra que alguns profissionais de Comunicação podem cometer falhas, na ânsia de divulgar informações de forma muito rápida e, não checar o acontecimento ou divulgar cálculos imprecisos ou depoimentos de fontes não-confiáveis. Entretanto, o profissional disseminador de notícias falsas[23, 10, 11] tende a ser uma pessoa ou grupo de pessoas cujo objetivo é bem definido e geralmente está ligado aos seguintes contextos:

Político – Pessoas e/ou empresas são contratadas para criar uma série de textos com ou sem imagens que objetivam enaltecer um candidato ou político para aumentar sua popularidade. A estratégia pode ser usada de forma inversa contra adversários.

Religioso – Representantes religiosos criam anúncios dos mais variados tipos a fim de adesão de novos participantes, podendo atacar, com notícias falsas, outras religiões e, até mesmo, criar pânico do fim do mundo para atrair novos fiéis.

Linearidade de Tempo – Muitos profissionais confeccionam notícias falsas com fatos e imagens antigas para confundir o destinatário.

Com o intuito de ajudar a classificar notícias falsas, o pesquisador César Augusto Gomes, da Universidade de Campinas–São Paulo, identificou, em seu artigo[26], 7 tipos mais comuns de *Fake News* sobre o tema abordado por este trabalho, que é a Covid-19. São eles:

- Manipulação de Conteúdo: quando o texto ou a figura é manipulado para enganar.

Como exemplo, o autor citou em seu artigo várias montagens de imagens associando informações enganosas sobre as medidas adotadas para conter o coronavírus e, em sua maioria, essas imagens eram montadas com a de jornais populares para ganharem credibilidade.

- **Conteúdo fabricado:** neste a informação é 100% falsa para atingir o objetivo de enganar. Neste estão todas as "Fake News" que indicam algum tipo de cura para a COVID-19. Neste contexto, um exemplo foi dado a respeito do componente químico da água tônica que seria o mesmo da hidroxicloroquina que, na época, era tido como um medicamento que combatia o vírus. Sobre essa "Fake News" várias agências de checagem como FatoOuFake[27], projeto Comprova[28] e boatos.org demonstraram que a autoria do conteúdo fabricado tinha viés político com o objetivo de se promover em cima da audiência.
- **Falsa Conexão:** De acordo com o autor, isso acontece quando títulos, ilustrações ou legendas não confirmam o conteúdo. Como exemplo foi citado o caso da culpa dos governadores dos estados que não obedeceram ao decreto presidencial de 03/02/2020 e teriam deixado as pessoas a se expor no carnaval e outros eventos ao vírus da COVID-19, quando na verdade, o decreto apenas autorizava a contratação de mais profissionais de saúde e não falava sobre impor restrições e distanciamento social. César Gomes afirma que a falsa conexão é muito parecida com o conteúdo enganoso, mas, diferente do último, ela distorce o conteúdo apresentando uma fonte oficial, no exemplo acima, o decreto presidencial, contando com a falta de leitura e checagem de seu consumidor para que a *Fake News* surta efeito.
- **Falso Contexto:** acontece quando o conteúdo é verdadeiro, mas é compartilhado com informação contextual falsa. No exemplo citado pelo pesquisador, pode-se perceber uma imagem mostrando a Polícia Federal visitando um cemitério e constatando caixões cheios de pedra quando na verdade esse registro foi feito em 2017 e era, de fato, uma visita da PF em um cemitério, mas com um contexto totalmente diferente, ou seja, o autor da *Fake News* procurou enganar pela data, associando ao assunto do Coronavírus.
- **Conteúdo Enganoso:** A partir de uma informação factual é gerada a desinformação a fim de denegrir ou exaltar pessoas ou grupos. sobre esse tipo de *Fake News*, o pesquisador cita a visita do ministro da saúde Nelson Teich, na época, no estado do Amazonas, na data de 04/05/2020. Naquela ocasião circularam nas redes sociais a informação de que só com a visita do ministro a mortalidade por Covid-19 na região já tinha diminuído. Fato que foi desmentido por várias agências de checagem como a FatoOuFake[27], do grupo Globo.

- **Sátira ou Paródia:** diz Gomes que este tipo não tem intenção de prejudicar, mas tem potencial para enganar. Isso porque, como afirma Fábio Victor[23]: A pessoa mal intencionada se apropria de um texto, imagem ou som original, manipulando-o para enganar as pessoas. Neste caso, mesmo a sátira ou paródia tendo o objetivo de tornar o assunto uma forma de diversão, pode ser tratada como um assunto para gerar discórdia e ódio. É o que acontece, por exemplo, quando revistas publicam ilustrações satirizando líderes religiosos.
- **Conteúdo Impostor:** Isso acontece quando fontes genuínas são imitadas. Neste caso, a informação faz parecer um conteúdo legítimo por ser muito parecida com de um canal informativo consagrado. Pode-se ter como exemplo as marcas esportivas como Nike, Adidas, que, são pirateadas como Mike, Nikke, Adibas, dentre outras. Da mesma forma acontece como fonte de sites jornalísticos, informativos laboratoriais e órgão de saúde pública.

Como se pode notar as consequências de propagação de notícias falsas vão desde um constrangimento por parte da suposta vítima até a manifestações de linchamento público e tomada de decisões por impulso, como destaca a pesquisadora [10], que cita como exemplo a invasão do Capitólio– congresso americano, em janeiro de 2021, que a autora classificou como um comportamento impulsionado por várias notícias falsas que objetivavam uma ideologia política.

1.9 Tipos de Notícias Falsas a Serem Detectadas

O maior desafio sobre o tratamento das notícias falsas é definir o que são "Fake News", não somente para as pessoas, neste caso, os consumidores de informações, mas para as máquinas, que tipo de padrões, regras e passos devem ser seguidos por elas para que cheguem a conclusão que um texto específico seja considerado falso.

Diante de uma imensidão de dados que reúnem textos, áudios e imagens que são disseminados como notícias, os meios de comunicação de massa[29], conhecidos como meios de comunicação "tradicionais" têm um grande desafio, assim como a comunidade científica em identificar a veracidade das informações divulgadas na internet a fim de apresentar para a sociedade os fatos de forma confiável.

Existem diversos sites, pertencentes a agência de notícias que, dedicam os profissionais a investigarem informações quanto sua veracidade, como "Portal aos Fatos[30]", "Projeto Comprova[28]", "Agência Veja Rio[31]", "Agência Brasil[32]", "G1 Fato ou Fake[27]", dentre outros que visam ajudar os leitores de notícias virtuais na formação de opinião. Para que esses sites especializados obtenham o resultado é necessária uma profunda pesquisa por parte dos profissionais para encontrar a verdade. Uma

forma de dinamizar esse trabalho e como solução computacional seria o uso de detectores de "Fake News", tendo o tempo da tarefa diminuído, como aponta uma pesquisa realizada na 24ª conferência internacional de sistemas de engenharia inteligente em 2020[33].

O pesquisador Emerson Wendt enumera em sua obra[34], os principais indícios em um texto para que o leitor possa identificar uma *Fake News* em sua rede social:

- Dados aleatórios com a aparência de verdade;
- Sensacionalismo e informações absurdas (não deixe de divulgar; atenção; tiraram do ar; essa a Globo não mostra, divulgue para seus contatos)
- Erros de Português
- Sites desconhecidos ou emprego da *typosquatting*[35]– que é uma forma de crime cibernético que envolve hackers que registram domínios com nomes deliberadamente mal soletrados de sites conhecidos. Os hackers fazem isso para atrair visitantes a sites alternativos, normalmente para fins maliciosos
- Emprego de *Caps Lock*(CAIXA ALTA)
- "Viralizando"rapidamente em redes sociais e aplicativos de mensagens

Embora os indícios sejam suficientes para identificar uma falsa informação publicada, as pessoas não costumam pesquisar ou como afirma Fábio Assolini em seu artigo[36], não costumam "checar" a veracidade das informações postadas em suas redes sociais, logo tecendo comentários ou compartilhando a mesma. Na pesquisa, 62% do total dos entrevistados afirmaram que não reconhecem uma *Fake News* quando recebem uma informação e, desse mesmo total, 2% nem mesmo sabiam o que significava *Fake News*.

Em relação a isto, percebe-se que há uma carência de iniciativa popular para evitar a propagação em massa de notícias falsas. Um dos motivos seria a enorme tarefa de ter que efetuar várias pesquisas a fim de constatar a veracidade de uma informação e, como elas são produzidas de forma contínua e em grande escala, muitos usuários de redes sociais preferem aceitar as informações que recebem como verdadeiras ou simplesmente ignorá-las[23]. Dessa forma, as empresas que controlam as redes sociais mais acessadas da internet têm investido cada vez mais na checagem de informações e punição dos usuários propagadores de notícias falsas[36, 25].

Desta forma, redes sociais como Facebook, Twitter, Instagram, Whatsapp, Telegram, por exemplo, mantém políticas de contenção das notícias falsas e crimes virtuais,

estabelecendo formas de denunciar e avisar seus usuários sobre o conteúdo que produzem ou consomem.

Até aqui percebe-se que para os usuários existem ferramentas capazes de detectar as *Fake News*, mas para que funcionem existem recursos computacionais a serem aplicados e que os indícios apresentados acima são adaptados de forma que os computadores possam processar as informações e apresentar um resultado satisfatório para o usuário decidir se o conteúdo produzido é verdadeiro ou falso. No capítulo a seguir ver-se-á algumas das principais técnicas para que se obtenha êxito na identificação de *Fake News*.

2 Técnicas Computacionais para Detectar Notícias Falsas

Neste capítulo são abordadas técnicas utilizadas dentro do conhecimento computacional a fim de identificar textos falsos, dentro do contexto identificado neste trabalho como notícias a serem detectadas como *Fake News*.

Em se tratando de tecnologia computacional para detecção de *Fake News* existem processos e até mesmo áreas com técnicas para classificação, processamento e métricas que satisfazem uma identificação de padrões que levem a uma decisão de determinada variável ser verdadeira ou falsa, como o que pretende-se no preterido trabalho. São áreas como Ciência de Dados, Estatística, Big Data, Machine Learning e; ferramentas computacionais como Toolkits, Processamento de Linguagens, Regressão Logística que serão descritos mais adiante.

2.1 Processamento de Linguagem Natural(PLN)

A detecção de notícias falsas passam pela utilização de técnicas, uma delas, que é fundamental para o presente trabalho, é, de acordo com o pesquisador James Allen, um grande recurso nas buscas por palavras-chave[37]. Isto porque o PLN ajuda dispositivos tecnológicos "entenderem" a linguagem do ser humano para que suas demandas sejam completadas.

De acordo com Silvio Pereira o PLN é muito vasto, pois consiste no desenvolvimento de modelos computacionais para a realização de tarefas que dependem de informações expressas em alguma linguagem natural[38], como o português, inglês, espanhol, enfim, além da conversão de uma linguagem do ser humano para outra de máquina, ainda há a complexidade de se estabelecer um modelo para ajudar na resolução de uma tarefa que é desejada. O método utilizado para isto pode ser o mapeamento de expressões, comparação de verbetes.

Um ponto fundamental para a classificação de palavras e adaptação para a linguagem de máquina é o pré-processamento. Nesta etapa, existe a necessidade que se tenha uma filtragem das palavras para que, mais adiante, haja uma estruturação da língua analisada.

2.2 NLTK

Esta é uma sigla para Natural Language Tool Kit, que em inglês, significa Conjunto de Ferramentas para Linguagem Natural. Sendo assim, esse é um recurso utilizado

pela linguagem de programação para trabalhar com processamento de linguagens naturais, manipulando-as para um fim específico. No caso adotado por este trabalho, tal ferramenta é integrada à linguagem Python como um dos pacotes utilizados para auxiliar na detecção de notícias falsas.

Primeiramente, A NLTK é importada por meio do comando `import`. Posteriormente, a classe contida no pacote pode ser instanciada e seus recursos podem ser acessados de forma encapsulada. No caso do *FakeCheck* as classes usadas foram XXXXXXXXX e YYYYYYYYYY. Elas foram suficientes para escanear as palavras armazenadas no banco de dados e convertê-las em binários a fim de reclassificá-las em árvores de decisão.

2.3 Ciência de Dados

Este capítulo apresenta uma explanação sobre a classificação dos dados, como eles se apresentam e como a tecnologia os aproveita para compor conhecimento útil para resoluções de problemas e tomadas de decisões como as que propomos neste trabalho, a binaridade de ratificar uma notícia como verdadeira ou falsa ao conhecê-la em uma rede social.

Com o crescimento dos dados produzidos na internet de forma exponencial houve a necessidade criar uma área específica para o estudo e análise dessas informações. Esta área ficou conhecida como *Data Science* ou Ciência de Dados, como uma ramificação da Ciência da Computação, tendo como principal objetivo desenvolver técnicas para apresentar um tratamento dos dados que os transformam em estatística, posteriormente em informação e ajudam na tomada de decisões.

2.4 Aprendizado de Máquina(AM)

De acordo com os estudos de Mueller e Massaron, a aprendizagem de máquina consiste em um conjunto de instruções para automatizar tarefas realizado por uma máquina – o que eles também chamam de aprendizagem automática[39].

Para Amaral 2016, aprendizado de máquina computacional é a aplicação de técnicas computacionais no intuito de achar padrões ocultos de dados. Esses padrões ocultos significam identificar dados implícitos[40].

Na definição de Arthur Lee Samuel, aprendizado de máquina é uma forma de Inteligência Artificial na qual as máquinas computacionais são capazes de melhorar a performance de uma tarefa específica com dados sem serem diretamente programados[41].

No contexto de *Big Data*, o aprendizado de máquina ganhou muita notoriedade.

Isso porque não adiantaria nada uma grande quantidade de dados se não fossem aproveitados para produzir informação e conhecimento.

Essa técnica está relacionada com outras ciências como a estatística e a inteligência artificial, mas está, intimamente ligada a outra técnica computacional que é fundamental nesse contexto que é a mineração de dados. Esta técnica, pressupõe uma série de etapas, que vão desde a identificação do negócio até a implementação. Amaral define seis etapas durante o processo de mineração dos dados, nas quais compreendem:

- Entendimento do Negócio: Onde se deve compreender todas as características de onde a mineração será aplicada e onde estará o sucesso da implementação;
- Entendimento dos dados: eles devem ser avaliados em termos de estrutura, relacionamentos, qualidade, quantidade e acesso;
- Preparação dos dados: para facilitar o processo os dados devem ser organizados, limpos e selecionados e, além disso, devem estar envolvidos na discretização, em que dados numéricos são transformados em dados nominais;
- Modelagem: Nesta etapa é construído um modelo. Ele será usado em novas instâncias ou dados novos acrescentados na base de dados;
- Avaliação: O modelo é avaliado quanto seu desempenho;
- Implementação: Etapa final em que propriamente a mineração de dados é aplicada.

Quanto às tarefas do aprendizado de máquina, pode-se destacar a classificação, o agrupamento e a associação. A mais comum delas é a classificação na qual os dados possuem uma classe que se pretende prever. Por exemplo[39], onde se quer saber a que espécie uma flor pertence. São coletados dados de uma "Íris", onde a classe é a espécie: setosa, versicolor ou virgínica. Quando se recebe as medidas das pétalas e da sépala de uma nova íris que não se conhece, utiliza-se um algoritmo de classificação que tentará classificar esta nova flor em uma das três espécies, baseado nos dados das outras flores. Se esses dados não tivessem sido classificados eles poderiam ser agrupados pela ordem e similaridade, sendo usada a segunda tarefa, que é o agrupamento. Finalmente, se existissem eventos como aparecimento de mofo, algumas regras poderiam ser definidas como umidade, iluminação, clima, solo, adubos químicos, constituindo a tarefa de associação. Uma observação feita por Amaral[40] é que se aquilo que se pretende prever for através de dados nominais, a tarefa é de classificação, entretanto, se for através de dados numéricos pode ser uma tarefa de regressão estatística. Classificação é uma tarefa supervisionada, enquanto agrupamento e associação são não-supervisionadas. Estas subdivisões serão detalhadas nas próximas sessões deste capítulo.

Basicamente para se obter a classificação são necessários três elementos na formação de uma base de dados, tais como atributos, classes e instâncias que formam tabelas ou entidades de dados. Como exemplo[40], em uma transação de varejo onde se busca identificar transações fraudulentas, terão um atributo especial, **fraude**, onde estará registrado, naquela instância, se a transação foi fraudulenta ou não.

Quanto ao algoritmo de classificação pode-se destacar que ele funciona com dados históricos, ou seja, fatos ocorridos e já estão classificados. Por exemplo, quando se quer a aprovação de um crédito precisa-se saber se o cliente é bom ou mau pagador. Uma vez que se tem vários dados de outros clientes, o algoritmo reconhece um modelo e, a cada nova instância (novo cliente adicionado), a partir do modelo estabelecido, o programa consegue prever se é apto a receber o crédito. Entretanto, para este processo existe uma margem de erro.

Data mining methods

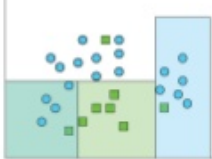
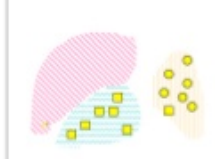
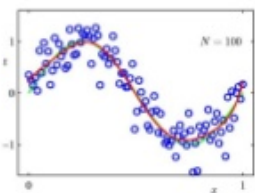

Predictive methods	Descriptive methods
Classification  <p>Learns a method for predicting the instance class from pre-labeled (classified) instances</p>	Clustering  <p>Finds "natural" grouping of instances given un-labeled data</p>
Regression  <p>An attempt to predict a continuous attribute</p>	Association Rules  <p>Method for discovering interesting relations between variables in large DBs</p>

Figura 2 – Gráficos de mineração de dados - Crédito QA Stack[2]

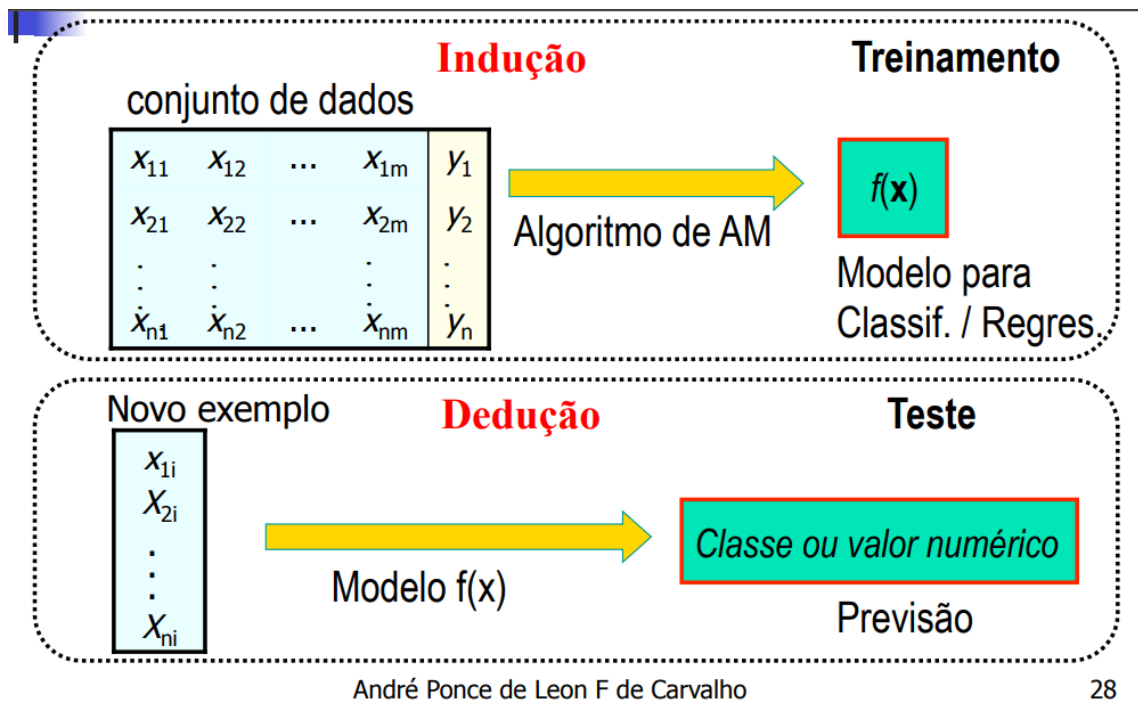


Figura 3 – Representação da Fórmula de Classificação/Regressão[3]

2.4.1 O Processo de Aprendizagem

Para se construir o modelo a partir da classificação, os dados históricos são separados em dois grupos: dados de treino e dados de teste. A divisão entre os dois grupos pode ser obtida por algumas técnicas – a mais comum é chamada de *Hold Out*. Nesse processo os dados são selecionados de forma aleatória e sem substituição em uma proporção de 70% para treino e 30% para teste. Outra técnica chamada de *Validação Cruzada*, em que cada registro é usado o mesmo número de vezes para treino e teste. Em seguida são trocados. Ainda há o *bootstrap*, onde os dados de treino e teste são amostras aleatórias com substituição[40].

Depois de definidos os dados de treino para o algoritmo, o modelo é construído e é iniciada a fase de teste da eficiência do modelo. Como o padrão já está classificado, o algoritmo vai classificar as novas instâncias, atribuindo sua própria classe. Posteriormente a essa etapa, inicia-se o teste de efetividade do modelo, comparando os valores dos dados de treino com os valores previstos. O resultado disso chama-se *Matriz de Confusão*. Esta, gera quatro índices: verdadeiros positivos, que são os dados que o algoritmo classificou como bons e de fato eram bons; verdadeiros falsos, onde o algoritmo classificou como ruins e a classe era ruim; falsos positivos, classificados como bons pelo algoritmo, mas eram ruins e; falsos negativos, em que o algoritmo classificou como ruins, mas eram bons[42, 43, 40].

Fernando Amaral[40] explana que dois indicadores principais podem ser obtidos a partir da matriz de confusão, a precisão – que é a taxa de acerto dividido pelo total de instâncias, e a taxa de erros, que é o total de erros dividido pelo total de instâncias. As métricas obtidas pela matriz de confusão podem ser representadas da seguinte forma:

- Taxa de Positivos Verdadeiros: $TPR = TP / (TP + FN)$
- Taxa de Negativos Verdadeiros: $TNR = TN / (TN + FP)$
- Taxa de Positivos Falsos: $FPR = FP / (TN + FP)$
- Taxa de Negativos Falsos: $FNR = FN / (TP + FN)$
- Precisão: $P = TP / (TP + FP)$
- Lembrança: $R = TP / (TP + FN)$

2.4.2 Aprendizado Supervisionado

Neste tipo, o aprendizado obtém instruções do que deve ser feito[44]. O algoritmo recebe um conjunto de dados rotulados para o modelo aprender o que é cada

classe/categoria e essas informações são fragmentadas em partes para porções de treino e teste.

Esse tipo de aprendizado é, de forma geral, aplicado quando a meta é prever eventos futuros. Caracteriza-se pela subdivisão de técnicas de classificação e regressão, as quais são usadas de acordo com a estruturação do modelo e a predição.

Classificação é um método de predição de uma classe discreta ou categoria. Por exemplo, suponha-se que um algoritmo de aprendizagem defina os seguintes automóveis: Sedan, Hatch e SUV. Se for apresentada uma nova instância, como um modelo Volkswagen Up, para o algoritmo, ele vai saber classificá-lo como hatch, visto que ele já aprendeu com os rótulos, anteriormente apresentados para ele. Existem alguns tipos de algoritmos de classificação, como KNN, Árvores de Decisão, SVM e Regressão Logística[44].

Regressão é o método de predição de um valor contínuo. Por exemplo, digamos que você vai investir seu dinheiro na compra de um imóvel. Não seria interessante você saber qual casa vai valorizar mais no futuro, ou qual bairro terá o maior crescimento urbano? Então para prever valores contínuos, conforme o caso, utiliza-se algum algoritmo desse tipo, como *regressão linear simples*, *regressão linear múltipla* e *regressão não linear*.

2.4.3 Aprendizado Não-supervisionado

Nesta técnica é fornecido um conjunto de dados não-rotulados, ou seja, não é "ensinado" ao modelo qual é o objetivo durante o processo. Caracteriza-se pela descoberta de padrões ou relacionamentos afins do que se deseja. De uma forma geral, ele é usado para achar particularidades implícitas nos dados. Nesta técnica são utilizados outros métodos, como:

- *Agrupamento* – onde há a busca pela similaridade entre os dados e, após identificar, segrega os itens entre os *clusters*(grupos) específicos. Com o uso de alguns algoritmos, pode-se definir o número exato de *clusters*. Pode ser utilizado para a segmentação de mercado (tipos de clientes, fidelidade), compactação de imagens, analisar e rotular novos dados, detectar comportamento anormal, dentre outros. Como exemplo de algoritmos de agrupamento, pode-se destacar: K-means, Mean-Shift, DBSCAN, Single Linkage e Complete Linkage.
- *Associação* – amplamente utilizada quando se tem uma sequência de algo e deseja encontrar padrões. Isso inclui técnicas para analisar carrinhos de compras, automatizar estratégia de marketing e outras tarefas relacionadas a eventos. Um exemplo clássico é a análise da cesta de mercado, que é uma técnica baseada na teoria de que se um cliente compra de um determinado grupo de itens, o mais provável é que ele compre um outro grupo de itens também. Outro exemplos: diagnóstico

médico. Pacientes com o sintoma X e Y, tende a ter o sintoma Z; Navegação na internet. Pessoa que visitou a página X de um site, provavelmente irá visitar a página Y.

Algumas são as técnicas usadas na regra de associação: *Apriori*, *Carma* e *Sequência*.

- *Redução de Dimensão* – é o processo de redução do número de variáveis aleatórias em consideração, a fim de obter um conjunto de variáveis principais. Em outras palavras, é simplesmente o processo de diminuição da dimensão de um determinado conjunto de recursos. Usado em sistemas de recomendação, análise de imagens falsas e gerenciamentos de risco. Algumas técnicas: Principal Component Analysis (PCA), Singular Value Decomposition (SVD), Latent Dirichlet Allocation (LDA), Latent Semantic Analysis (LSA), t-SNE(para visualização).

2.4.4 Aprendizado por Reforço

O objetivo desse tipo de aprendizado é um modelo de ação adequado que maximize a recompensa acumulada total do agente. Diferentemente dos aprendizados anteriores, o *Reinforcement Learning* é utilizado nas ocasiões em que seu problema não é, unicamente, relacionados a grupo de dados, mas que tenha ambiente para lidar, como exemplo, um cenário de *game* ou uma cidade onde trafegam carros autônomos. Afirma Camila Waltrick que, "sobreviver" em um ambiente é a ideia central do aprendizado por reforço, que buscará "obter o máximo de pontos possíveis" através do seu agente que, por sua vez, será conduzido por um supervisor externo. Utiliza o método tentativa e erro: Acerto = recompensa; Erro = punição. Por isso, um exemplo para ilustrar melhor esse aprendizado seria os *games*, mas ele também é utilizado em outras aplicações, como a robótica. São tipos de aprendizagem por reforço algoritmos como: Q-learning e SARSA(Estado-Ação-Recompensa-Estado-Ação).

2.5 Regressão Logística(RL)

Definição: é uma técnica estatística que, por meio de um conjunto de observações, objetiva produzir um modelo que permita prever um resultado através de outros valores apresentados de forma contínua. Então, a partir desse modelo formado, é possível calcular ou prever a probabilidade de um evento ocorrer, dado uma observação aleatória[45].

Quanto à aplicabilidade, a Regressão Logística(RL) é frequentemente utilizada pelas ciências médicas e humanas de uma forma ampla, pois com sua característica, pode apresentar previsões que auxiliam na tomada de decisões para diagnosticar doenças, estipular riscos, determinar comportamentos[46] e, além disso, para o marketing, a RL

tem sido muito útil, pois permite prever a possibilidade de um grupo de indivíduos comprar um certo produto; de analisar o interesse de usuários de redes sociais em várias áreas de compras. Na política a RL tem sido útil para prever a possibilidade de um candidato ganhar uma eleição. Neste trabalho a RL é utilizada para prever a possibilidade de uma notícia publicada ser verdadeira ou falsa.

Ainda sobre a aplicabilidade, Gonzales[45] afirma que o modelo de regressão logística permite:

- modelar a probabilidade de um evento ocorrer dependendo dos valores das variáveis independentes, que podem ser categóricas ou contínuas. Nesse caso, ao inserir dados no modelo, o resultado será um valor entre 0 e 1 que representa esta probabilidade.
- calcular a chance provável de um evento acontecer a partir de uma observação selecionada randomicamente, contra a probabilidade do evento não ocorrer. A probabilidade de um evento ocorrer, contra ele não ocorrer, é uma razão de probabilidades, $\frac{p}{1-p}$ que é chamada chance[45].
- prever o efeito do conjunto de variáveis sobre a variável dependente binária. Para este caso, pode-se concluir, por exemplo, que uma variável é bastante significativa para o modelo de regressão enquanto que a outra não contribui para sua eficácia.
- classificar observações, estimando a probabilidade de uma delas estar em uma categoria determinada. Nesse caso, a RL pode informar que, por exemplo[45], uma pessoa que tem muito peso e ou idade avançada pode estar propenso à diabetes.

Quanto à função logística, de acordo com Amaral[42], conforme a entrada seja grande e positiva, ela se aproxima cada vez mais de 1 e, conforme a entrada seja grande e negativa, ela se aproxima mais de 0. Tal função pode ser representada pelo seguinte gráfico:




Figura 4 – Gráfico da Regressão Logística

2.6 Exemplos de Detectores de Fake News

3 FakeCheck para Detectar Fake News regionais do Amapá

A nomenclatura "Detecta Potoca" deu-se, primeiramente, pelo objetivo central da pesquisa definido no pré-projeto que é detectar notícias falsas regionais do Amapá. Sendo assim foi escolhido um vocábulo referente à notícias falsas – potoca, que quer dizer falsidade, mentira, de acordo com estudantes e jornalistas regionais do Amapá, como pode ser observado no artigo da jornalista Alcinéa Cavalcante[47].

Descrever detalhadamente a metodologia utilizada tanto do lado de desenvolvimento quanto do lado usual das ferramentas tecnológicas. As "prints" desse algoritmo serão expostas em uma sessão separada – de figuras

Este nome para o protótipo foi escolhido porque o vocábulo *potoca* é bem peculiar no Amapá e quer dizer mentira ou falsidade, portanto, adequado ao tema e aos objetivos.

3.1 Justificativa

É notório que para os usuários de redes sociais e da *web* como um todo podem verificar o conteúdo do que consomem, ou seja, as informações que recebem se são verdadeiras ou falsas. Entretanto, essa prática, em muitos casos se torna muito cansativa e pouco prática, levando em consideração que a todo momento um conteúdo muito grande dessas informações são depositados e, a fonte da informação pode não ser confiável ou pode ser falsa. Assim sendo, os protótipos de detecção auxiliam automatização desse processo, apresentando um resultado provável quase que instantaneamente para ajudar na formação de opinião e tomada de decisões não só para as pessoas quanto para empresas, como as próprias redes sociais que demonstram e bloqueiam disseminadores de *Fake News*.

Quanto à escolha do software FakeCheck pode-se destacar as características que se apresenta, pois é de código aberto, de livre utilização, com ferramentas relativamente simples de ser usadas, com um bom desempenho para treinamento e aprendizado de máquinas.

Quanto à escolha do aplicativo de rede social Twitter, embora não seja a rede social mais usada no Brasil, vale ressaltar que ele possui uma particularidade importante para a presente pesquisa – os textos são públicos e podem ser acessados de forma geral, ou seja, existem menos limitações para acesso aos dados que se pretende do que em aplicativos como Facebook, Whatsapp ou Instagram, dos quais o feed de notícias é privativo, ou seja, as publicações são restritas a grupos ou a pessoas em particular,

dificultando uma análise abrangente a que se pretende neste trabalho.

3.2 Objetivos

3.2.1 Geral

Utilizar o protótipo FakeCheck para treinar um detector de notícias falsas sobre o assunto covid-19 no aplicativo Twitter

3.2.2 Específicos

Treinar o protótipo com o método de regressão logística

Manter uma acurácia maior que 75%

3.3 Metodologia

Diretrizes para a elaboração de um Fake News Corpus(Base de Dados). Ao construir um conjunto de dados de notícias falsas, foram seguidos nove requisitos de criação de banco de dados para notícias falsas proposto por (Rubin et al., 2016)[18]. Especificamente, os autores sugeriram que tal *corpus* deveria (1) incluir ambas notícias falsas e reais, (2) contêm apenas texto itens de notícias, (3) têm uma verdade fundamental verificável, (4) ser homogêneo em comprimento e (5) estilo de escrita, (6) conter notícias de um período de tempo predefinido, (7) ser entregue da mesma maneira e pelo mesmo propósito (por exemplo, humor, notícias de última hora) para falsas e casos reais, (8) ser disponibilizados publicamente, e (9) deve levar as diferenças culturais e de idioma para conta.

3.4 Recursos Utilizados

Para confecção de todo o presente trabalho foi utilizado um computador básico, contendo em seu hardware um processador intel celeron n3700, 4gb de memória ram e 128gb de SSD. Já em seu conjunto de softwares instalados estão o sistema operacional Windows 10 pro, linguagem de programação Python 3.9, IDE Sublime Text 3.

Conceito básico de Matriz Confusão utilizado no protótipo:

O protótipo apresentado neste trabalho é um software baseado em código de reuso[48], em que, uma vez disponibilizado o código-fonte, modificações foram realizadas para adequar o programa ao objetivo do trabalho, que é detectar notícias falsas no contexto amapaense.

A técnica usada como base para funcionamento do programa foi a Regressão Logística, uma técnica de comparativa estatística em que o objetivo é comparar variáveis em torno de um mesmo fim, como afirma XXXXXXXX:

3.4.1 Métricas de Avaliação

Verdadeiro Positivo: Quando análise e texto forem considerados *Fake News*;

Verdadeiro Negativo: Quando a análise for *Fake News*, mas o texto for verdadeiro;

Falso Positivo: Quando a análise for verdadeira, mas o texto for considerado *Fake News* e;

Falso Negativo: Quando ambos forem considerados verdadeiros.

3.5 Relatório do Software

O presente software tem por objetivo fazer o treinamento de máquina a partir de um banco de dados específico contendo postagens da rede social Twitter para identificar se as postagens possuem um conteúdo verdadeiro ou falso.

O método utilizado para compilar os dados e demonstrar os resultados é a regressão logística.

AGRESTI define o método de regressão logística como um conjunto de previsões estatísticas para se obter um resultado predefinido[49]. Outro conceito que se pode inferir sobre regressão logística como sendo uma técnica que faz modelagem de previsão, cuja principal característica é o fato de sua variável dependente ser categórica e geralmente binária (dicotômica), indicando dois possíveis valores ou categorias[43].

Para este caso, o código usa, especificamente, o modelo de regressão logística binária[43], em que o dependente é uma dicotomia (neste caso, verdadeiro ou “fake”) e os independentes são de qualquer tipo.

Como recursos utilizados para funcionamento do software, foi utilizado o reuso do software, como colaboração ao desenvolvimento de software, tendo como linguagem de programação principal usada Python, na versão 3.8.

Vale ressaltar que para o software usado neste trabalho funcione corretamente é necessária a instalação de algumas bibliotecas específicas do Python, que podem ser obtidas por meio dos seguintes comandos em um terminal de qualquer sistema operacional:

As bibliotecas importadas para a aplicação foram:

- **re**: Pacote responsável pelo reconhecimento da regressão logística desenvolvida

Algoritmo 1: Instalação das Bibliotecas Python

```
1 pip install seaborn
2 pip install nltk
3 pip install sklearn
```

no código-fonte;

- **nltk** (natural language tool kit): Pacote responsável pelo desenvolvimento de instruções e processamento de linguagem natural a ser contida no código.
- **PorterStemmer**: O algoritmo stemming de Porter (ou 'Porter stemmer') é um processo para remover as terminações morfológicas e inflexionais mais comuns das palavras em inglês. Seu uso principal é como parte de um processo de normalização de termos que geralmente é feito ao configurar sistemas de Recuperação de Informações[50].
- **Sklearn**: Esta biblioteca permite que a linguagem Python trabalhe com o aprendizado de máquina. Nela encontram-se predefinidos diversos algoritmos que auxiliarão em análises, métricas, processamentos e avaliações de dados[51].
- **Pandas**: A biblioteca "pandas" importada na linha 23 como "pd" é uma biblioteca específica para análise de dados. Ela dá suporte para manipular conjunto extensos de dados de forma simples. Também permite que operações com matrizes e vetores tenham uma performance satisfatória[51].
- **TfidfVectorizer**: é uma sub biblioteca da Sklearn que tem como objetivo plotar os gráficos ao final do programa para a análise de dados de forma organizada.
- **LogisticRegressionCV**: esta biblioteca torna possível a aplicação do método de modelagem de previsão estatística, assim como explanado no início deste relatório.

Após o carregamento das bibliotecas específicas a que necessita o software, na linha 27, um comando é dado para carregamento do banco de dados que contém todas as informações coletadas das redes sociais a serem analisadas pelo programa, umas "fake" e outras "true". Dessa forma, o programa faz o treinamento identificando padrões a serem seguidos para novas postagens.

Na linha 29, o comando "print" imprime na tela o cabeçalho descritivo do software. A seguir, nas linhas 31 e 32, o vetor "classificação" é preenchido com Strings para fazer diferenciação entre as palavras-chave maiúsculas e minúsculas a serem pontos de referência para a pesquisa. As palavras são "fake" e "true".

Na linha 38 o objeto DataFrame, através da variável “df”, retorna uma amostra aleatória de itens em um eixo do objeto carregado. O comando da linha 41 faz uma contagem dos valores contidos no vetor “classificacao” para ser utilizado adiante.

A seguir, nas linhas 43 e 45, os comandos são simplesmente a impressão do cabeçalho e dos elementos contidos no vetor “text” para organização visual da análise de dados. Das linhas 47 a 57, os comandos do algoritmo são postulados para pré-processamento e criação de regras de sintaxe para que sejam aceitas ou recusadas pela aprendizagem de máquina. Ao final são impressos em tela os textos contidos no vetor “text”.

Nas linhas 59 e 60 a biblioteca SnowballStemmer é importada ao programa para que todo o conteúdo importado ao banco de dados seja reconhecido na língua portuguesa. Uma vez que “Stemming” é a técnica que remove os afixos das palavras, deixando apenas seu radical[52], nas linhas 62 e 63 o comando procura “tokenizar” as palavras, separando-as para a análise de dados.

Das linhas 65 a 78 são importadas bibliotecas complementares da “nltk” e editados parâmetros de configuração à variável “tfidf” para que a mesma seja acrescentada ao eixo X da tupla do banco de dados adicionado nesta pesquisa. O eixo Y é preenchido com os valores do vetor “classificação”. Em seguida, são impressos em tela todos os valores de ambos os eixos X e Y nas linhas 80 e 82.

Na linha 84, o código utiliza o método “train_test_split” nas variáveis “X” e “Y” fazendo com que os dados passem pelo treinamento e testagem de acordo com as regras léxicas predefinidas.

Seguindo com o algoritmo, na linha 86, uma variável é criada, denominada “clf”, recebendo a função *LogisticRegressionCV* para armazenar alguns dados estatísticos obtidos por meio do treinamento e do teste das variáveis submetidas pelo programa. Alguns parâmetros como “call values” e “accuracy” pertencem à função para comparações posteriores.

Das linhas 88 a 90 o programa faz a serialização dos dados, abrindo, processando e armazenando as informações contidas no arquivo de modelo “fake_news_model.sav” e depositando o que foi registrado na variável “clf”.

Nas linhas 92 a 95, o software cria uma nova variável chamada “saved_clf” e carrega os dados do modelo e deixa preparado para novas iterações imprimindo o que já está armazenado na tela.

Em seguida, das linhas 97 a 101 novamente o método “LogisticRegressionCV” é usado com parâmetros específicos, dessa vez na variável “saved_clf” a fim de se obterem novos dados comparativos e na linha 103 do software o método “score” aplicado na mesma variável compara os eixos X e Y para diagramação.

A partir da linha 107 é feita uma avaliação do modelo usando a matriz de confusão. Nela é criada uma nova variável denominada "y_pred" que recebe um método "predict", onde pretende prever rótulos de classe para amostras no eixo X.

Na linha 110 as métricas são importadas da biblioteca "sklearn" para utilização na matriz de confusão. Dessa forma é criada mais uma variável, chamada "cnf_matrix" que recebe os dados obtidos pelo método "metrics.confusion_matrix". Tais dados são formulados no eixo Y. Posteriormente a isto são impressos os dados em tela da matriz de confusão contidos na variável "cnf_matrix" através do comando *print*.

Na sequência são visualizados os resultados do modelo na forma de uma matriz de confusão usando as bibliotecas do Python *matplotlib* e *seaborn*. E para a visualização propriamente da matriz de confusão é utilizada a biblioteca *heatmap*.

O carregamento destas bibliotecas possibilita a exposição de gráficos na visualização do programa. Neste caso, das linhas 123 a 125 são importadas bibliotecas específicas e renomeadas para facilitar sua utilização.

Nas linhas 128 a 132 são utilizados comandos para plotagem dos dados contidos nas variáveis que representam os eixos dos vetores que foram treinados e testados pelo software.

Das linhas 134 a 140 simplesmente é organizada a forma como os valores serão expostos no gráfico, incluindo todas as legendas e títulos e, ao final o comando *show* exhibe o gráfico pronto.

Posteriormente a plotagem dos gráficos, realiza-se a avaliação das métricas na matriz de confusão, considerando acurácia, precisão e "recall". Existe uma regra que se a acurácia possuir uma taxa de classificação igual ou maior que 72%, o resultado será satisfatório e; sobre a precisão, o programa avalia o quão preciso é o modelo, ou seja, quando um modelo faz uma previsão, o programa avalia com que frequência ela está correta. Sobre o *recall*, neste caso específico, o modelo de regressão logística previu que as notícias coletadas do Twitter são "Fake News", isso acontecerá em "x%" do tempo.

Isto posto, na linha 148, da biblioteca *sklearn.metrics* são importadas as classes *classification_report* e *accuracy_score*.

Das linhas 150 a 152 são impressas apenas as métricas apuradas acima.

Ainda há, no programa a exposição da Curva ROC. Ela significa Receiver Operating Characteristic (ROC), que é um gráfico da taxa de verdadeiro positivo em relação à taxa de falso positivo. Mostra a relação entre sensibilidade e especificidade.

Por fim, há a inclusão do pontuador AUC (area under the curve) área sob a curva, representa o grau ou medida de separabilidade. Um modelo com AUC mais alta é melhor em prever verdadeiros positivos e verdadeiros negativos[53].

Neste programa a pontuação AUC 1 representa o classificador perfeito e 0,5 representa um classificador sem valor, sendo assim, nas linhas 159, 160 e 162 são criadas três variáveis para receber as métricas de avaliação dos pontuadores de acordo com a probabilidade de se obter uma classificação satisfatória.

Na linha 167 são criadas mais duas variáveis para receber as métricas da curva ROC.

Na linha 169 uma variável denominada *AUC* é criada para receber as métricas testadas do *score* da curva ROC e compor a pontuação AUC.

Para finalizar das linhas 170 a 172 são plotados os gráficos com as métricas avaliadas acima.

4 Resultado e Discussão

4.1 Banco de Dados

O banco de dados foi construído, tendo como base o aplicativo de rede social *Twitter* com notícias relacionadas à pandemia do covid-19 durante o período do 19/01/2021 a 14/03/2021. Cada notícia é descrita pelas seguintes colunas:

1. **id**: índice que numera a posição da linha ou notícia
2. **título**: O título da notícia
3. **corpo**: O corpo da notícia
4. **classificacao**: A classificação, na qual cada notícia é considerada verdadeira (true) ou falsa (fake), e
5. **link**: O link da notícia no aplicativo Twitter.

O banco de dados é composto de 248 linhas e 4 colunas salvas num arquivo de extensão ".csv", onde os elementos das colunas são separados por tabulações. Dado que a forma dos dados é uma planilha, criamos um arquivo de dados do tipo *dataframe* usando o comando:

Algoritmo 2: Criar arquivo do tipo Dataframe

1 df = pd.read_csv('BD-detectaPotoca.csv', sep = '\t')
--

As 5 primeiras linhas do dataframe pode ser visualizada usando o método *head*

Algoritmo 3: Exibir as 5 primeiras linhas do Dataframe

1 df.head()

Contabilizamos o número de notícias verdadeiras ou falsas com o método *value_counts*:

Algoritmo 4: Número de Notícias Falsas e Verdadeiras

1 df['classificacao'].value_counts()

fake: 139

true: 109

Name: classificacao, dtype: int64

	id	título	corpo	classificacao	link
0	1	coronavac	O que é imunidade de grupo? Por que se fala ta...	true	https://t.co/908PzQa8XA
1	2	covid-19	Não podemos esquecer que o próprio STF proibiu...	fake	https://t.co/pDmzuni2Mb
2	3	Morte por falta de oxigênio	Por falta de oxigênio sete pessoas da mesma fa...	true	https://twitter.com/i/events/13516721834335600...
3	4	Vachina	A Vachina pode ter 50% de eficácia, mas a verb...	fake	https://twitter.com/leandroruschel/status/1352...
4	5	vachina	Vacina Pfizer tem entre 19% e 29% de eficácia ...	fake	https://twitter.com/antoinebachelin/status/135...

Figura 5 – Exemplo de uma tabela do banco de dados do Fakecheck

É necessário embaralhar o *dataframe* para evitar **sesgo** ao escolher os elementos a serem usados no conjunto de treinamento e no conjunto de validação. No pandas embaralhamos o *dataframe* com o método *sample*:

Algoritmo 5: Dataframe embaralhado

```
1 df.sample(frac=1).reset_index(drop=True)
```

Usando *df.head()* pode-se observar as 5 primeiras linhas com o *dataframe* já embaralhado:

	id	título	corpo	classificacao	link
0	99	Cautela pós-covid	Ser vacinado significa que você corre muito me...	true	https://twitter.com/DrTomFrieden/status/136098...
1	7	coronavirus	Pesquisa revela que Bolsonaro executou uma 'es...	fake	https://twitter.com/roxmo/status/1352635087754...
2	198	Nova Cepa P1	Cepa P.1 é mais contagiosa e pode reinfectar q...	true	https://twitter.com/revistasuper/status/136747...
3	210	Criação de novos leitos de UTI	Ministério da Saúde autoriza financiamento de ...	true	https://twitter.com/CoronavirusBra1/status/137...
4	45	Covid é farsa	Gente abram os olhos é claro q é um golpe ã se...	fake	https://twitter.com/Marcioolivei100/status/124...

Figura 6 – Base de Dados com o Dataframe embaralhado

Foi dividido o *dataframe* *df* em duas partes: *df1* com as 235 primeiras linhas e o *df2* com as últimas 13 linhas do *dataframe* *df*. O *dataframe* *df1* vai ser usado no processo de treinamento e validação, enquanto o *dataframe* *df2* vai ser usado para testar o comportamento do aprendizado de máquina na avaliação de notícias novas de modo independente.

```
df1 = df[0 : 236]
```

```
df2 = df[236 : 248]
```

A classificação de notícias *Fake* e *True* no *Dataframe* *DF1*:

```
df1['classificacao'].value_counts()
```

fake: 133

true: 103

Name: classificacao, dtype: int64

A classificação de notícias *Fake* e *True* no *Dataframe* *DF2*:

```
df2['classificacao'].value_counts()
```

fake: 6

true: 6

Name: classificacao, dtype: int64

4.2 Pré-Processamento

O corpo das notícias tem que ser pré-processadas para que o algoritmo de aprendizado de máquina possa fazer o tratamento da informação. Para entender melhor este processo vejamos o corpo da linha 51 do *dataframe* *df1*:

```
df1['corpo'][50]
```

"A pilantragem sem limites. Acabo de receber um paciente na UTI que fez uso de um 'protocolo' com: ivermectina, cloroquina, anitta, prednisona oral, dexametasona injetável, clexane em dose plena, amoxicilina e azitromicina. É muito surreal que isso não seja motivo de perder o CRM!"

Eliminamos caracteres como pontos, vírgulas, aspas, etc e transformando todo o texto em minúsculas, usando a seguinte função:

Listing 4.1 – Função de Preprocessor

```
1 def preprocessor(text):
2     text = re.sub('<[^>]*>', '', text)
3     text = re.sub(r'[\^\\w\\s]', '', text)
4     text = text.lower()
5     return text
```

Aplicamos a função *preprocessor* ao corpo dos *dataframes* *df1* e *df2*:

```
df1['corpo'] = df1['corpo'].apply(preprocessor)
```



```
df2['corpo'] = df2['corpo'].apply(preprocessor)
```

O efeito da função *preprocessor* é visualizada na linha 51 do *dataframe* *df1*:

```
<center: df1['corpo'][50]
```

onde se pode observar tudo o texto em minúsculas e ausências de caracteres separadores como vírgula, ponto, etc.

"a pilantragem sem limites acabo de receber um paciente na uti que fez uso de um protocolo com ivermectina cloroquina anitta prednisona oral dexametasona injetável clexane em dose plena amoxicilina e azitromicina é muito surreal que isso não seja motivo de perder o crm"

Para lematizar o corpo do *dataframe* *df1* usamos o kit de ferramentas de linguagem natural (NLTK) importando o lematizador *SnowballStemmer* com o corpus *stopwords* em português. Vetorizamos o vocabulário na variável **tfidf** usando o módulo *TFidfVectorizer*:

```
1 tfidf = TfidfVectorizer(stop_words=stopwords.words('portuguese'),
2 strip_accents=None,
3 lowercase=False,
4 preprocessor=None,
5 tokenizer=tokenizer_porter,
6 use_idf=True,
7 norm='l2',
8 smooth_idf=True)
```

O vocabulário gerado em *tfidf* é gerado com: **tfidf.vocabulary**.

Alguns valores do vocabulário são mostrados a seguir:

```
1 {'ser': 1542,
2  'vacin': 1703,
3  'signif': 1555,
4  'voc': 1736,
5  'corr': 450,
6  'muit': 1123,
7  'men': 1084,
8  'risc': 1491,
9  'fic': 749,
10 'gravement': 825,
11 'doent': 581,
12 'caus': 330,
```

```
13 'covid': 458,  
14 'aind': 130,  
15 'pod': 1300,  
16 'infect': 905,  
17 'outr': 1227,  
18 'pesso': 1278,  
19 'tod': 1641,  
20 'dev': 539,  
21 'continu': 428,  
22 'usand': 1689,  
23 'masc': 1132,  
24 'limit': 1016,  
25 'temp': 1621,
```

Definimos o objeto X contendo toda a informação da lematização:

```
X = tfidf.fit_transform(df1['corpo'])
```

Cuja saída mostra que X é um *array* de dimensão 236×1771236×1771, assim como os índices, as frequências e probabilidades das palavras do dicionário.

```
{'_shape': (236, 1771),
 'maxprint': 50,
 'indices': array([ 434, 1562, 680, ..., 1748, 1126, 1542], dtype=int32),
 'indptr': array([ 0, 31, 52, 76, 95, 124, 135, 142, 163, 181, 200,
 228, 241, 258, 269, 295, 315, 330, 351, 380, 406, 423,
 455, 477, 499, 528, 547, 569, 592, 620, 642, 667, 690,
 714, 730, 747, 781, 806, 817, 842, 865, 880, 901, 916,
 938, 961, 983, 1003, 1024, 1041, 1066, 1093, 1113, 1139, 1167,
 1192, 1220, 1241, 1255, 1274, 1296, 1320, 1327, 1349, 1367, 1394,
 1405, 1413, 1438, 1448, 1473, 1492, 1507, 1531, 1544, 1570, 1593,
 1615, 1623, 1633, 1659, 1686, 1700, 1718, 1742, 1763, 1772, 1791,
 1812, 1835, 1862, 1884, 1907, 1920, 1941, 1955, 1983, 2000, 2021,
 2039, 2053, 2080, 2108, 2116, 2127, 2155, 2175, 2204, 2214, 2238,
 2266, 2281, 2297, 2321, 2341, 2359, 2388, 2417, 2434, 2465, 2473,
 2483, 2506, 2533, 2559, 2583, 2608, 2637, 2666, 2674, 2690, 2713,
 2735, 2750, 2758, 2768, 2787, 2812, 2830, 2847, 2875, 2897, 2922,
 2951, 2970, 2985, 3013, 3027, 3043, 3060, 3074, 3088, 3114, 3136,
 3153, 3177, 3198, 3210, 3231, 3268, 3280, 3289, 3317, 3336, 3353,
 3365, 3378, 3390, 3408, 3431, 3457, 3463, 3478, 3497, 3523, 3546,
 3566, 3585, 3601, 3624, 3640, 3670, 3690, 3703, 3727, 3739, 3759,
 3778, 3807, 3831, 3842, 3861, 3875, 3899, 3918, 3921, 3941, 3955,
 3984, 4008, 4037, 4049, 4075, 4090, 4116, 4139, 4156, 4178, 4198,
 4225, 4254, 4263, 4270, 4284, 4297, 4323, 4337, 4359, 4380, 4398,
 4421, 4442, 4465, 4485, 4495, 4519, 4539, 4561, 4579, 4595, 4617,
 4627, 4657, 4691, 4709, 4728, 4742], dtype=int32),
 'data': array([0.17595199, 0.18194983, 0.18904376, ..., 0.10853108, 0.46278017,
 0.14589588])}
```

Figura 7 – Frequências e Probabilidades das palavras do Dicionário

Associado a cada linha de X associamos o valor da classificação *true* o *fake*:

```
df1.classificação.values
```

O array Y é mostrado a seguir:

```
array(['true', 'fake', 'true', 'true', 'fake', 'fake', 'fake', 'true',  
      'true', 'fake', 'fake', 'true', 'fake', 'fake', 'true', 'fake',  
      'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake',  
      'fake', 'fake', 'fake', 'true', 'fake', 'fake', 'fake', 'true',  
      'fake', 'true', 'true', 'fake', 'fake', 'fake', 'fake', 'true',  
      'fake', 'true', 'fake', 'fake', 'fake', 'true', 'true', 'true',  
      'fake', 'fake', 'true', 'true', 'true', 'fake', 'fake', 'fake',  
      'fake', 'true', 'true', 'fake', 'fake', 'fake', 'fake', 'fake',  
      'fake', 'fake', 'true', 'true', 'fake', 'true', 'fake', 'true',  
      'true', 'true', 'true', 'fake', 'true', 'fake', 'true', 'true',  
      'true', 'true', 'fake', 'true', 'true', 'true', 'fake', 'fake',  
      'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'true', 'fake',  
      'fake', 'true', 'fake', 'true', 'fake', 'fake', 'true', 'true',  
      'fake', 'true', 'true', 'fake', 'true', 'fake', 'fake', 'true',  
      'fake', 'true', 'true', 'fake', 'fake', 'fake', 'true', 'true',  
      'true', 'true', 'fake', 'true', 'fake', 'fake', 'fake', 'fake',  
      'fake', 'fake', 'true', 'fake', 'fake', 'true', 'fake', 'fake',  
      'fake', 'true', 'fake', 'fake', 'fake', 'true', 'true', 'fake',  
      'true', 'true', 'fake', 'true', 'fake', 'true', 'fake', 'true',  
      'fake', 'true', 'true', 'fake', 'fake', 'true', 'fake', 'true',  
      'true', 'true', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake',  
      'true', 'fake', 'true', 'true', 'fake', 'fake', 'true', 'true',  
      'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'true',  
      'fake', 'true', 'true', 'fake', 'true', 'true', 'fake', 'true',  
      'fake', 'true', 'fake', 'true', 'true', 'true', 'fake', 'true',  
      'fake', 'fake', 'true', 'fake'], dtype=object)
```

Figura 8 – Array do Eixo Y

X e Y serão usados no modelo de aprendizado de máquina para detecção de notícias *fake*.

4.3 Dados de Treinamento e Dados de Teste

Dividimos o conjunto de dados X em dados de treinamento **X_train** e dados de teste **X_test**. Analogamente obtém-se os dados associados do conjunto y, divididos em dados de treino **y_train** e dados de teste **y_test**. O tamanho dos dados de treino é 70% e do teste é 30% em relação aos dados originais. Para a obtenção dos conjuntos de treino e teste é usado o módulo **train_test_split** do *sklearn*:

```
1 X_train, X_test, y_train,
2 y_test = train_test_split(x, y, random_state=0,
3 test_size=0.3, shuffle=False)
```

Resumo dos dados treino X_train:

```
{'_shape': (165, 1758),
 'maxprint': 50,
 'indices': array([ 825,  826,  334, ..., 460,  848, 1239], dtype=int32),
 'indptr': array([  0,  14,  43,  64,  83, 112, 141, 166, 191, 203, 222,
    247, 269, 295, 314, 340, 354, 381, 407, 415, 435, 457,
    485, 510, 524, 541, 563, 574, 595, 606, 616, 633, 652,
    675, 689, 713, 740, 761, 787, 808, 828, 853, 867, 887,
    909, 921, 942, 963, 987, 1006, 1034, 1068, 1088, 1099, 1127,
    1142, 1172, 1185, 1204, 1224, 1250, 1268, 1291, 1320, 1340, 1355,
    1371, 1397, 1421, 1438, 1456, 1479, 1513, 1535, 1562, 1577, 1591,
    1605, 1624, 1644, 1667, 1704, 1734, 1765, 1783, 1799, 1824, 1837,
    1868, 1892, 1916, 1948, 1971, 1985, 2008, 2030, 2049, 2056, 2084,
    2106, 2122, 2129, 2153, 2175, 2202, 2225, 2254, 2278, 2284, 2302,
    2326, 2343, 2368, 2394, 2406, 2435, 2447, 2476, 2497, 2516, 2524,
    2542, 2567, 2596, 2626, 2654, 2672, 2675, 2694, 2717, 2740, 2748,
    2769, 2796, 2811, 2833, 2851, 2865, 2891, 2907, 2933, 2944, 2959,
    2985, 3004, 3017, 3027, 3054, 3083, 3106, 3133, 3150, 3168, 3188,
    3207, 3231, 3259, 3279, 3301, 3317, 3331, 3351, 3362, 3379, 3400,
    3416], dtype=int32),
 'data': array([0.32165307, 0.32165307, 0.32165307, ..., 0.12783937, 0.24489975,
    0.09865306])}
```

Figura 9 – Dados de treinamento e dados de teste 1

```

Resumo dos dados treino y_train:
array(['true', 'fake', 'fake', 'true', 'fake', 'fake', 'true', 'true',
      'true', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake', 'fake',
      'fake', 'fake', 'true', 'fake', 'fake', 'fake', 'fake', 'true',
      'fake', 'true', 'true', 'fake', 'fake', 'true', 'fake', 'fake',
      'fake', 'fake', 'fake', 'fake', 'true', 'true', 'fake', 'fake',
      'true', 'fake', 'true', 'fake', 'fake', 'true', 'fake', 'fake',
      'fake', 'fake', 'fake', 'true', 'fake', 'fake', 'fake', 'true',
      'true', 'true', 'true', 'fake', 'fake', 'true', 'true', 'fake',
      'fake', 'true', 'fake', 'true', 'fake', 'fake', 'true', 'true',
      'true', 'fake', 'true', 'true', 'fake', 'fake', 'true', 'true',
      'true', 'fake', 'fake', 'true', 'fake', 'fake', 'true', 'fake',
      'fake', 'fake', 'true', 'true', 'fake', 'true', 'fake', 'true',
      'true', 'fake', 'true', 'fake', 'fake', 'fake', 'fake', 'true',
      'fake', 'fake', 'fake', 'fake', 'fake', 'true', 'fake', 'true',
      'fake', 'fake', 'true', 'fake', 'fake', 'true', 'true', 'true',
      'true', 'true', 'true', 'true', 'true', 'fake', 'fake', 'true',
      'true', 'fake', 'fake', 'true', 'fake', 'fake', 'fake', 'true',
      'true', 'true', 'true', 'fake', 'true', 'fake', 'true', 'true',
      'true', 'fake', 'fake', 'true', 'true'], dtype=object)

```

Figura 10 – Dados de treinamento e dados de teste 2

```

Resumo dos dados teste y_test:
array(['fake', 'fake', 'fake', 'true', 'true', 'fake', 'fake', 'fake',
      'fake', 'true', 'fake', 'true', 'fake', 'true', 'true', 'fake',
      'fake', 'true', 'true', 'fake', 'fake', 'true', 'fake', 'fake',
      'fake', 'fake', 'fake', 'true', 'fake', 'true', 'true', 'true',
      'fake', 'fake', 'fake', 'true', 'true', 'fake', 'true', 'fake',
      'fake', 'true', 'true', 'fake', 'fake', 'fake', 'true', 'true',
      'true', 'true', 'fake', 'fake', 'fake', 'fake', 'true', 'true',
      'true', 'true', 'fake', 'true', 'fake', 'true', 'fake'],
      dtype=object)

```

Figura 11 – Dados de treinamento e dados de teste 3

4.4 Regressão Logística

O modelo de otimização usado para o aprendizado de máquina é a regressão logística. Os dados `X_train` e `y_train` são treinados como o módulo do **sklearn LogisticRegressionCV** com `cv=5` (número de *folds* usados). O algoritmo usado no modelo de otimização é o **lbfgs**, foram testados também os algoritmos de otimização *newton-cg* e *liblinear* obtendo resultados idênticos. O critério de validação cruzada foi o de *accuracy*. A tolerância para o critério de parada foi de 0,0001 ou um máximo de 300 iterações, o grau de regularização do algoritmo de otimização foi de `cs=10`. Os resultados da regressão logística foram armazenados na variável `clf`:

```
1  clf = LogisticRegressionCV(Cs=10, class_weight=None, cv=5,
2  dual=False,
3  fit_intercept=True, intercept_scaling=1.0, l1_ratios=None,
4  max_iter=300, multi_class='auto', n_jobs=-1, penalty='l2',
5  random_state=0, refit=True, scoring='accuracy',
6  solver='lbfgs', tol=0.0001, verbose=3).fit(X_train,y_train)
```

Resumo da regressão linear:

```
{'Cs': 10,
 'fit_intercept': True,
 'cv': 5,
 'dual': False,
 'penalty': 'l2',
 'scoring': 'accuracy',
 'tol': 0.0001,
 'max_iter': 300,
 'class_weight': None,
 'n_jobs': -1,
 'verbose': 3,
 'solver': 'lbfgs',
 'refit': True,
 'intercept_scaling': 1.0,
 'multi_class': 'auto',
 'random_state': 0,
 'l1_ratios': None,
 'n_features_in_': 1758,
 'classes_': array(['fake', 'true'], dtype=object),
 'Cs_': array([1.00000000e-04, 7.74263683e-04, 5.99484250e-03, 4.64158883e-02,
               3.59381366e-01, 2.78255940e+00, 2.15443469e+01, 1.66810054e+02,
               1.29154967e+03, 1.00000000e+04]),
 'n_iter_': array([[[ 6,  2,  2,  3,  6, 15, 17, 16, 16,  9],
                    [ 6,  1,  2,  4,  5, 12, 13, 19, 26, 17],
                    [ 6,  2,  2,  4,  6,  8, 18, 16, 21,  9],
                    [ 6,  2,  4,  5,  6, 19, 11, 19, 16, 16],
                    [ 6,  2,  4,  5,  6, 14, 29, 20, 21,  9]]])
```

Figura 12 – Regressão Logística 1

Foi testada a acurácia com os dados treinados **x_train** e **y_train**:

```
clf.score(x_train, y_train)
```

Resultado = 1.0

Como era esperado a acurácia com os dados do treino é igual a 1 ou 100

Testamos agora a exatidão com os dados teste **x_test** e **y_test**:

```
clf.score(x_test, y_test)
```

Resultado = 0.8450704225352113

Logo, o grau de acerto do algoritmo de aprendizado de máquina é de 84,51%.

4.5 Avaliação do Modelo: Métricas

Os valores preditos pelo modelo de regressão logística para o conjunto teste **x_test** é armazenada na variável **y_pred**:

```
y_pred = clf.predict(x_test)
```

Os valores preditos **y_pred** são confrontados com os valores reais **y_test** usando o módulo *metrics.confusion_matrix*:

```
y_pred = clf.predict(x_test)
```

Cujo resultado é a matriz de confusão:

```
array([[35, 5], [ 6, 25]], dtype=int64)
```

A matriz de confusão pode ser visualizada graficamente usando o módulo *HeatMap*:

```
sns.heatmap(pd.DataFrame(cnf_matrix), annot=True, cmap="YlGnBu",fmt='g')
```




Figura 15 – Matriz de Confusão

Na matriz de confusão o valor 0 representa notícias fake e o valor 1 representa notícias verdadeiras. Destes valores temos,

1. TP = 35: o modelo acertou corretamente 35 de um total de 40 notícias fake
2. TF = 25: o modelo acertou corretamente 25 de total de 31 notícias verdadeiras
3. FP = 6: denominado falso positivo. O modelo errou ao prever 6 notícias como fake sendo elas notícias verdadeiras
4. FN = 5: denominado falso negativo. O modelo errou ao prever 5 notícias como verdadeiras sendo elas fake

Dos dados da matriz de confusão vamos calcular a acurácia, precisão, recall e f1-score:

$$\begin{aligned}
 \text{acuracia} &= \frac{TP + TN}{TP + TN + FP + FN} = \frac{35 + 25}{35 + 25 + 6 + 5} = \frac{60}{71} = 84,51\% \\
 \text{precisao fake} &= \frac{TP}{TP + FP} = \frac{35}{35 + 6} = \frac{35}{41} = 85,36\% \\
 \text{recall fake} &= \frac{TP}{TP + FN} = \frac{35}{35 + 5} = \frac{35}{40} = 87,50\% \\
 \text{f1-score fake} &= \frac{2}{\frac{1}{\text{precisao}} + \frac{1}{\text{recall}}} = \frac{2}{\frac{1}{0,8536} + \frac{1}{0,8750}} = 86,42\%
 \end{aligned}$$

Observa-se que o modelo tem uma alta acurácia (84,51%), mas esta medida não especifica se a acurácia é relacionada as notícias fake, verdadeiras ou a ambas. Uma medida complementar é a precisão, a qual tem um valor alto (85,36%) e está associada a previsibilidade das notícias fake. Uma outra medida complementar é o recall, a qual associa a capacidade de prever notícias fake considerando os falsos negativos, cujo valor é também alto (87,50%). No caso que a precisão e o recall tenha valores discrepantes se considera o f1-score que é a media harmônica entre estes valores, obtendo-se a capacidade de prever notícias fake um alto f1-score (86,42%). Analogamente se pode calcular a precisão, recall e f1-score para a capacidade do modelo de prever as notícias verdadeiras. No sklearn, isto pode ser calculado com o modulo `classification_report`:

```
classification_report(y_test, y_pred)
```

com resultados:

Figura 16 – Cálculo da Acurácia

```

---Test Set Results---
Accuracy with logreg: 0.8450704225352113

```

	precision	recall	f1-score	support
fake	0.85	0.88	0.86	40
true	0.83	0.81	0.82	31
accuracy			0.85	71
macro avg	0.84	0.84	0.84	71
weighted avg	0.84	0.85	0.84	71

Figura 17 – Resultados da Acurácia

Observa-se que os valores das métricas para as notícias *fake* são iguais que as calculadas acima. A capacidade de prever notícias verdadeiras também é alta: precisão de 83%, recall de 81% e f1-escore de 82%.

A curva ROC (Receiver Operating Characteristic) é um gráfico da taxa de verdadeiros positivos em relação a taxa de falsos positivos. Um escore **auc** da curva ROC próximo de 1 indica que o modelo consegue separar corretamente as notícias *fake* das notícias verdadeiras, enquanto um escore abaixo de 0,5 indica que o modelo não consegue fazer esta separação e, portanto, o modelo tem baixo poder preditivo. Este escore **auc** é calculado com o modulo do *sklearn metrics.roc_auc_score*.

No gráfico da curva ROC observa-se que **auc** tem o valor de 0,9467, próximo de 1 e portanto o modelo de regressão logística para aprendizado de máquina para notícias *fake* consegue fazer a separação das notícias corretamente.




Figura 18 – Curva ROC

5 Conclusão e Contribuições para Trabalhos Futuros

Montar estatísticas, quadros, tabelas, gráficos e outros recursos que possam evidenciar toda comparação numérica para explicar que conclusões foram obtidas, contendo, inclusive observações sobre os objetivos alcançados ou não ao final da pesquisa.

Referências

- [1] M. da Saúde do Governo Federal do Brasil, “Covid-19 no brasil: Dados e Óbitos,” *Site Oficial do Ministério da Saúde*. <https://shortest.link/1KKw>.
- [2] Q. Stack, “Diferença entre classificação e clustering,” 2021. <https://qastack.com.br/programming/5064928/difference-between-classification-and-clustering-in-data-mining>.
- [3] A. P. de Leon de Carvalho, “Aprendizado de máquina.”
- [4] N. Traquina, *Teorias do Jornalismo*, vol. 2. Insular, 2008.
- [5] F. Pena, *Teorias do Jornalismo*, vol. 1. Contexto, 2005.
- [6] M. Pillar and R. Toniol, *Cientistas Sociais e o Coronavírus*, vol. 1. Tribo da Ilha, 2020.
- [7] F. Siqueira and P. Monteiro, *Jornalismo em tempos de pandemia: reconfigurações na TV e na internet*, vol. 1. UFPB, 2020.
- [8] F. Figueiredo, “Ap passa a ter multas para quem divulga ‘fake news’; governo quer criar delegacia especializada,” <https://g1.globo.com/ap/amapa/noticia/2020/06/25/ap-passa-a-ter-multas-para-quem-divulga-fake-news-governo-quer-criar-delegacia-especializada.ghtml>.
- [9] <https://www12.senado.leg.br/institucional/datasenado/publicacaodatasenado?id=mais-de-80-dos-brasileiros-acreditam-que-redes-sociais-influenciam-muito-a-opinio-das-pessoas>.
- [10] P. et al, vol. unique. UNESCO, 2018.
- [11] K. Shu, H. Liu, J. Han, L. Getoor, W. Wang, J. Gehrke, and R. Grosman, *Detecting Fake News on Social Media*. Morgan & Claypool, 2019. <https://ieeexplore.ieee.org/document/8758609>.
- [12] “Uso de notícias falsas e mídia social pelos canais de notícias principais da Índia,” in 2020 16^o IEEE International Colloquium on Signal Processing Its Applications (CSPA).
- [13] P. da República, “Código penal,” *Planalto*. http://www.planalto.gov.br/ccivil_03/decreto-lei/del2848compilado.htm.
- [14] A. D. L. Celia Marques Telles, “Escrita e fala: O que ensinam os textos não literários,” *Universidade Federal da Bahia*. <http://e-revista.unioeste.br/index.php/linguaseletras/article/download/4140/3199>.

- [15] L. e. a. Massarani, "Narrativas sobre vacinação em tempos de fake news: uma análise de conteúdo em redes sociais," 06 2021.
- [16] "Uso de internet, televisão e celular no brasil." <https://educa.ibge.gov.br/jovens/materias-especiais/20787-uso-de-internet-televisao-e-celular-no-brasil.html>.
- [17] A. A. Monther Aldwairi, "Detecting fake news in social media networks," p. 8, 07 2018.
- [18] V. Rubin, N. Conroy, Y. Chen, and S. Cornwell, "Fake news or truth? using satirical cues to detect potentially misleading news," 06 2016.
- [19] I. Manickam, A. S. Lan, G. Dasarathy, and R. G. Baraniuk, "Ideotrace: A framework for ideology tracing with a case study on the 2016 u.s. presidential election," in *2019 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*, pp. 274–281, 2019.
- [20] O. P.-A. de Saúde, "Histórico da pandemia de covid-19," 2020. <https://www.paho.org/pt/covid19/historico-da-pandemia-covid-19>.
- [21] M. Gonzatto, "Linha do tempo: veja a evolução da covid-19 no mundo ao completar um ano," *GZH Saúde*. <https://gauchazh.clicrbs.com.br/saude/noticia/2020/12/linha-do-tempo-veja-a-evolucao-da-covid-19-no-mundo-ao-completar-um-ano-ckjbv0iwx009o019w4kx1h0cd.html>.
- [22] E. G1, "Coronavírus: veja a cronologia da doença no brasil," *Site G1*. <https://g1.globo.com/bemestar/coronavirus/noticia/2020/04/06/coronavirus-veja-a-cronologia-da-doenca-no-brasil.ghtml>.
- [23] F. Victor, "Como funciona a engrenagem das notícias falsas no brasil," *Folha de S. Paulo*. <https://m.folha.uol.com.br/ilustrissima/2017/02/1859808-como-funciona-a-engrenagem-das-noticias-falsas-no-brasil.shtml>.
- [24] J. Naughton, "Fake news about covid-19 can be as dangerous as the virus," <https://www.theguardian.com/commentisfree/2020/mar/14/fake-news-about-covid-19-can-be-as-dangerous-as-the-virus>.
- [25] A. Bedi, N. Pandey, and S. K. Khatri, "A framework to identify and secure the issues of fake news and rumours in social networking," in *2019 2nd International Conference on Power Energy, Environment and Intelligent Control (PEEIC)*, pp. 70–73, 2019.

- [26] C. A. Gomes, “Os 7 tipos de fake news sobre a covid-19,” *UNICAMP*. <https://www.blogs.unicamp.br/covid-19/os-7-tipos-de-fake-news-sobre-a-covid-19/>.
- [27] <https://g1.globo.com/fato-ou-fake/>.
- [28] <https://projetocomprova.com.br/>.
- [29] C. Castilho, “A desinformação como estratégia política desafia o jornalismo,” 2016. <http://www.observatoriodaimprensa.com.br/imprensa-em-questao/desinformacao-como-estrategia-politica/>.
- [30] <https://www.aosfatos.org/aos-fatos-e-noticia/>.
- [31] <https://vejario.abril.com.br/cidade/fake-news-pandemia-desinformacao-lupa/>.
- [32] <https://agenciabrasil.ebc.com.br/>.
- [33] Y. Yanagi, R. Orihara, Y. Sei, Y. Tahara, and A. Ohsuga, “Detecção de notícias falsas com comentários gerados para artigos de notícias,” in *2020 IEEE 24^a Conferência Internacional de Sistemas de Engenharia Inteligente (INES)*, pp. 85–90, 2020.
- [34] E. Wendt, vol. unique. Livraria do Advogado, 2019.
- [35] E. K. Labs, “O que é typosquatting? definição e explicação,” *Kaspersky Official Site*. <https://www.kaspersky.com.br/resource-center/definitions/what-is-typosquatting>.
- [36] F. Assolini, “62% dos brasileiros não sabem reconhecer uma notícia falsa,” *Kaspersky Official Site*. https://www.kaspersky.com.br/about/press-releases/2020_62-dos-brasileiros-nao-sabem-reconhecer-uma-noticia-falsa.
- [37] J. Allen, vol. unique. Pearson, 1994.
- [38] S. do Lago Pereira, “Processamento de linguagem natural,” 2021. <https://www.ime.usp.br/slago/IA-pln.pdf>.
- [39] J. P. Mueller and L. Massaron, vol. unique. Alta Books, 2019.
- [40] F. Amaral, vol. 1. Alta Books, 2016.
- [41] A. L. Samuel, “Some studies in machine learning using the game of checkers,” *IBM Journal of Research and Development*.
- [42] J. Grus, vol. unique. Alta Books, 2016.
- [43] P.TAN, M.STEINBACH, and V.KUMAR, vol. 1. Ciência Moderna, 2009.

- [44] C. Waltrick, “Machine learn - o que é, tipos de aprendizagem de máquina, algoritmos e aplicações,” *Revista Medium*, 2000. <https://medium.com/camilawaltrick/introducao-machine-learning-o-que-e-tipos-de-aprendizado-de-maquina-445dcfb708f0>.
- [45] L. Gonzales, “Regressão logística e suas aplicações,” 2018. <https://monografias.ufma.br/jspui/bitstream/123456789/3572/1/LEANDRO-GONZALEZ.pdf>.
- [46] A. M. S. Batista, vol. unique. Vida Económica, 2015.
- [47] A. Cavalcante, “Nosso jeito de falar – gírias do amapá,” 2020. <https://www.alcinea.com/geral/nosso-jeito-de-falar-girias-do-amapa>.
- [48] B. Meyer, “The reusability challenge,” *Computer*, vol. 29, no. 2, pp. 76–78, 1996.
- [49] A. Agresti, vol. 1. Wiley-Interscience, 2002.
- [50] V. dos Santos, “Stemming: Como reduzir uma palavra ao seu radical,” 2018. encurtador.com.br/bkN23.
- [51] R. S. Ferreira, “10 ferramentas e bibliotecas para trabalhar com data mining e big data,” 2017. <https://imasters.com.br/data/10-ferramentas-e-bibliotecas-para-trabalhar-com-data-mining-e-big-data-parte-01>.
- [52] <https://www.nltk.org/howto/stem.html>.
- [53] <https://ichi.pro/pt/metricas-de-avaliacao-parte-3-78903211225634>.